Tipología y ciclo de vida de los datos: Práctica 2

Azucena González (azucenagm) y Jesús Márquez (jmarquez01)

Mayo 2019

Índice

Introducción

El hundimiento del RMS Titanic es uno de los naufragios más infames de la historia. El 15 de abril de 1912, durante su viaje inaugural, el Titanic se hundió después de chocar con un iceberg, matando a 1502 de 2224 pasajeros y tripulantes. Esta tragedia conmocionó a la comunidad internacional y condujo a mejores regulaciones de seguridad para los buques, dado que una de las principales razones de tal pérdida de vidas fue que no había suficientes botes salvavidas para los pasajeros y la tripulación.

El objetivo del siguiente **estudio KDD** es realizar un análisis que permita **determinar qué tipos de personas podrían sobrevivir** al hundimiento. Se aplicarán, por tanto, varias técnicas de minería de datos y *machine learning* para obtener un modelo que permita predecir con un nivel de calidad aceptable qué pasajeros sobrevivirían a la tragedia.

Descripción del dataset

Se ha obtenido el conjunto de datos disponible en Kaggle (https://www.kaggle.com) con el listado de pasajeros del Titanic y si sobrevivieron o no al naufragio. Los datos recogidos contienen los siguientes campos:

- PassengerId: identificador numérico (entero) para cada pasajero.
- Survived: que toma dos posibles valores e indica si el pasajero sobrevivió. 0 significa que no sobrevivió, 1 que sí lo hizo.
- Pclass: número entero que indica la clase en la que viaja el pasajero. Se ha codificado como 1 para primera clase, 2 para segunda clase y 3 para tercera clase.
- Name: nombre del pasajero.
- Sex: sexo del pasajero. Se indica male para hombres y female para mujeres.
- Age: número entero que representa la edad del pasajero.
- SibSp: número de hermanos/cónyuges que se encontraban a bordo.
- Parch: número de padres/hijos que se encontraban a bordo.
- Ticket: identificador del billete.
- Fare: numérico con decimales que representa la tarifa del billete.
- Cabin: número de cabina.
- Embarked: puerto de embarque, habiéndose codificado como C para Cherbourg, Q para Queenstown y S para Southampton.

El dataset se encuentra dividido en dos ficheros:

- **titanic.train.csv** o conjunto de entrenamiento, que contiene 892 registros y que suele emplearse para entrenar las técnicas supervisadas de data mining que se utilicen durante el estudio.
- **titanic.test.csv** o conjunto de prueba, con 419 observaciones, que suele utilizarse en algunos algoritmos supervisados para evaluar la calidad del modelo construido. Este fichero no contiene el campo *Survived*, pero puede encontrarse esta información en **titanic.test.solution.csv**.

Antes de iniciar la carga de los ficheros correspondientes, se ejecutan las librerías que se van a usar durante el análisis.

```
# Se comprueba si los paquetes de las librerías a usar están descargados. Si no, se
# procede a su descarga e instalación

# Librerías con utilidades para matrices de correlación
if(!"car" %in% installed.packages()) install.packages("car", depend=TRUE)
library(car)

if(!"corrplot" %in% installed.packages()) install.packages("corrplot", depend=TRUE)
library(corrplot)

# Visualización de gráficas
if(!"ggplot2" %in% installed.packages()) install.packages("ggplot2", depend=TRUE)
```

```
library(ggplot2)

# Paleta de colores para gráficas
if(!"RColorBrewer" %in% installed.packages()) install.packages("RColorBrewer",
                                                               depend=TRUE)
library(RColorBrewer)

# Funciones y utilidades para el tratamiento de data frames
if(!"dplyr" %in% installed.packages()) install.packages("dplyr", depend=TRUE)
library(dplyr)

# Funciones relacionadas con curvas ROC
if(!"pROC" %in% installed.packages()) install.packages("pROC", depend=TRUE)
library(pROC)

# Utilidades para formateo avanzado de tablas
if(!"kableExtra" %in% installed.packages()) install.packages("kableExtra", depend=TRUE)
library(kableExtra)

# Funciones relacionadas con el algoritmo kNN (VIM)
if(!"VIM" %in% installed.packages()) install.packages("VIM", depend=TRUE)
library(VIM)

# Funciones relacionadas con paquete caret
if(!"caret" %in% installed.packages()) install.packages("caret", depend=TRUE)
library(caret)

# Funciones relacionadas con los árboles de decisión
if(!"C50" %in% installed.packages()) install.packages("C50", depend=TRUE)
library(C50)

# Funciones para la ejecución del algoritmo random forest
if(!"randomForest" %in% installed.packages()) install.packages("randomForest",
                                                               depend=TRUE)
library(randomForest)
```

Carga de los datos

Se realiza la carga de los dos conjuntos de datos, indicando que la primera línea es la cabecera de datos y que deben eliminarse los espacios en blanco que pueda haber entre campos. También se realiza la carga del fichero que contiene los valores de la variable Survived para el conjunto de datos de prueba.

```
# Datos para entrenamiento
trainData <- read.csv("titanic.train.csv", header=TRUE, strip.white=TRUE,
                      stringsAsFactors=FALSE)

# Datos para test
testData <- read.csv("titanic.test.csv", header=TRUE, strip.white=TRUE,
                     stringsAsFactors=FALSE)

# Datos con el valor de la variable Survived para los datos de test
testSolution <- read.csv("titanic.test.solution.csv", header=TRUE, strip.white=TRUE,
                     stringsAsFactors=FALSE)
```

```
# Se visualizan los primeros registros para comprobar que la carga ha sido correcta
kable(head(trainData)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.2500		S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.9250		S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1000	C123	S
5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.0500		S
6	0	3	Moran, Mr. James	male	NA	0	0	330877	8.4583		Q

```
kable(head(testData)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
892	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292		Q
893	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000		S
894	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875		Q
895	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625		S
896	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875		S
897	3	Svensson, Mr. Johan Cervin	male	14.0	0	0	7538	9.2250		S

```
kable(head(testSolution)) %>% kable_styling(latex_options=c("striped"))
```

PassengerId	Survived
892	0
893	1
894	0
895	0
896	1
897	0

```
# Se muestra la estructura de ambos datasets para revisar los tipos de datos asignados
# por defecto
str(trainData)
```

```
## 'data.frame':    891 obs. of  12 variables:
##  $ PassengerId: int  1 2 3 4 5 6 7 8 9 10 ...
##  $ Survived   : int  0 1 1 1 0 0 0 0 1 1 ...
##  $ Pclass     : int  3 1 3 1 3 3 1 3 3 2 ...
##  $ Name       : chr  "Braund, Mr. Owen Harris" "Cumings, Mrs. John Bradley (Florence Briggs Thayer)"
##  $ Sex        : chr  "male" "female" "female" "female" ...
##  $ Age        : num  22 38 26 35 35 NA 54 2 27 14 ...
##  $ SibSp      : int  1 1 0 1 0 0 0 3 0 1 ...
##  $ Parch      : int  0 0 0 0 0 0 0 1 2 0 ...
##  $ Ticket     : chr  "A/5 21171" "PC 17599" "STON/O2. 3101282" "113803" ...
##  $ Fare       : num  7.25 71.28 7.92 53.1 8.05 ...
##  $ Cabin      : chr  "" "C85" "" "C123" ...
##  $ Embarked   : chr  "S" "C" "S" "S" ...
```

```
str(testData)
```

```
## 'data.frame':    418 obs. of  11 variables:
##  $ PassengerId: int  892 893 894 895 896 897 898 899 900 901 ...
##  $ Pclass     : int  3 3 2 3 3 3 3 2 3 3 ...
##  $ Name       : chr  "Kelly, Mr. James" "Wilkes, Mrs. James (Ellen Needs)" "Myles, Mr. Thomas Francis
##  $ Sex        : chr  "male" "female" "male" "male" ...
##  $ Age        : num  34.5 47 62 27 22 14 30 26 18 21 ...
```

```
##  $ SibSp      : int  0 1 0 0 1 0 0 1 0 2 ...
##  $ Parch      : int  0 0 0 0 1 0 0 1 0 0 ...
##  $ Ticket     : chr  "330911" "363272" "240276" "315154" ...
##  $ Fare       : num  7.83 7 9.69 8.66 12.29 ...
##  $ Cabin      : chr  "" "" "" "" ...
##  $ Embarked   : chr  "Q" "S" "Q" "S" ...
```

```
str(testSolution)
```

```
## 'data.frame':    418 obs. of  2 variables:
##  $ PassengerId: int  892 893 894 895 896 897 898 899 900 901 ...
##  $ Survived   : int  0 1 0 0 1 0 1 0 1 0 ...
```

Integración y selección de los datos

Integración

Aunque inicialmente se nos facilita el conjunto total de datos separado entre el conjunto de pruebas y el de entrenamiento, vamos a proceder a tratar ambos conjuntamente para su preprocesado y limpieza. Posteriormente, antes del entrenamiento de los modelos, se realizará una nueva división para obtener ambos conjuntos.

En primer lugar, debe incorporarse al conjunto de datos de prueba la variable objeto del análisis, Survived, que se encuentra en el dataset que hemos denominado *testSolution*. Después se unificarán en un único dataframe los dos conjuntos de datos.

```
# Se realiza un inner join por PassengerId
testDataSolution <- merge(x=testData, y=testSolution, by="PassengerId")

# Se visualizan los primeros registros para comprobar que el join ha sido correcto
kable(head(testDataSolution)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
892	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292		Q	0
893	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000		S	1
894	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875		Q	0
895	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625		S	0
896	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875		S	1
897	3	Svensson, Mr. Johan Cervin	male	14.0	0	0	7538	9.2250		S	0

```
# Se muestra la estructura del dataset es correcta (mismas variables y del mismo tipo)
str(testDataSolution)
```

```
## 'data.frame':    418 obs. of  12 variables:
##  $ PassengerId: int  892 893 894 895 896 897 898 899 900 901 ...
##  $ Pclass     : int  3 3 2 3 3 3 3 2 3 3 ...
##  $ Name       : chr  "Kelly, Mr. James" "Wilkes, Mrs. James (Ellen Needs)" "Myles, Mr. Thomas Francis
##  $ Sex        : chr  "male" "female" "male" "male" ...
##  $ Age        : num  34.5 47 62 27 22 14 30 26 18 21 ...
##  $ SibSp      : int  0 1 0 0 1 0 0 1 0 2 ...
##  $ Parch      : int  0 0 0 0 1 0 0 1 0 0 ...
##  $ Ticket     : chr  "330911" "363272" "240276" "315154" ...
##  $ Fare       : num  7.83 7 9.69 8.66 12.29 ...
##  $ Cabin      : chr  "" "" "" "" ...
##  $ Embarked   : chr  "Q" "S" "Q" "S" ...
##  $ Survived   : int  0 1 0 0 1 0 1 0 1 0 ...
```

```
# Por último, se unen los dos conjuntos de datos en un único data frame
titanicData <- rbind(trainData, testDataSolution)

# A modo de comprobación, se visualizan los primeros registros
kable(head(titanicData)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.2500		S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.9250		S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1000	C123	S
5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.0500		S
6	0	3	Moran, Mr. James	male	NA	0	0	330877	8.4583		Q

```
# Y la estructura del data frame resultante
str(titanicData)
```

```
## 'data.frame':    1309 obs. of  12 variables:
##  $ PassengerId: int  1 2 3 4 5 6 7 8 9 10 ...
##  $ Survived   : int  0 1 1 1 0 0 0 0 1 1 ...
##  $ Pclass     : int  3 1 3 1 3 3 1 3 3 2 ...
##  $ Name       : chr  "Braund, Mr. Owen Harris" "Cumings, Mrs. John Bradley (Florence Briggs Thayer)"
##  $ Sex        : chr  "male" "female" "female" "female" ...
##  $ Age        : num  22 38 26 35 35 NA 54 2 27 14 ...
##  $ SibSp      : int  1 1 0 1 0 0 0 3 0 1 ...
##  $ Parch      : int  0 0 0 0 0 0 0 1 2 0 ...
##  $ Ticket     : chr  "A/5 21171" "PC 17599" "STON/O2. 3101282" "113803" ...
##  $ Fare       : num  7.25 71.28 7.92 53.1 8.05 ...
##  $ Cabin      : chr  "" "C85" "" "C123" ...
##  $ Embarked   : chr  "S" "C" "S" "S" ...
```

Se revisan los tipos asignados a cada variable: Survived, Pclass, Sex y Embarked son variables categóricas por lo que se deben declarar como factores.

```
# Se convierten a factores las variables indicadas
titanicData$Survived <- factor(titanicData$Survived, levels=c(0, 1),
                               labels=c("No", "Si"))
titanicData$Pclass <- as.factor(titanicData$Pclass)
titanicData$Sex <- as.factor(titanicData$Sex)
titanicData$Embarked <- as.factor(titanicData$Embarked)

# Se comprueba el cambio de tipos
str(titanicData)
```

```
## 'data.frame':    1309 obs. of  12 variables:
##  $ PassengerId: int  1 2 3 4 5 6 7 8 9 10 ...
##  $ Survived   : Factor w/ 2 levels "No","Si": 1 2 2 2 1 1 1 1 2 2 ...
##  $ Pclass     : Factor w/ 3 levels "1","2","3": 3 1 3 1 3 3 1 3 3 2 ...
##  $ Name       : chr  "Braund, Mr. Owen Harris" "Cumings, Mrs. John Bradley (Florence Briggs Thayer)"
##  $ Sex        : Factor w/ 2 levels "female","male": 2 1 1 1 2 2 2 2 1 1 ...
##  $ Age        : num  22 38 26 35 35 NA 54 2 27 14 ...
##  $ SibSp      : int  1 1 0 1 0 0 0 3 0 1 ...
##  $ Parch      : int  0 0 0 0 0 0 0 1 2 0 ...
##  $ Ticket     : chr  "A/5 21171" "PC 17599" "STON/O2. 3101282" "113803" ...
##  $ Fare       : num  7.25 71.28 7.92 53.1 8.05 ...
##  $ Cabin      : chr  "" "C85" "" "C123" ...
##  $ Embarked   : Factor w/ 4 levels "","C","Q","S": 4 2 4 4 4 3 4 4 4 2 ...
```

Además, se revisa que no existan observaciones duplicadas (la variable PassengerId debería ser única):

```
# Se comprueba si existen valores duplicados
sum(duplicated(titanicData$PassengerId))
```

```
## [1] 0
```

Selección de los datos de interés

Reducción

Reducción de la dimensionalidad

Tras la revisión inicial del *dataset* y las variables que lo forman, se decide eliminar la relativa al nombre del pasajero, ya que no debería tener relevancia alguna en el estudio.

```
# Se elimina la variable Name, pues no se va a considerar en el estudio
titanicData <- select(titanicData, -c("Name"))
str(titanicData)
```

```
## 'data.frame':    1309 obs. of  11 variables:
##  $ PassengerId: int  1 2 3 4 5 6 7 8 9 10 ...
##  $ Survived   : Factor w/ 2 levels "No","Si": 1 2 2 2 1 1 1 1 2 2 ...
##  $ Pclass     : Factor w/ 3 levels "1","2","3": 3 1 3 1 3 3 1 3 3 2 ...
##  $ Sex        : Factor w/ 2 levels "female","male": 2 1 1 1 2 2 2 2 1 1 ...
##  $ Age        : num  22 38 26 35 35 NA 54 2 27 14 ...
##  $ SibSp      : int  1 1 0 1 0 0 0 3 0 1 ...
##  $ Parch      : int  0 0 0 0 0 0 0 1 2 0 ...
##  $ Ticket     : chr  "A/5 21171" "PC 17599" "STON/O2. 3101282" "113803" ...
##  $ Fare       : num  7.25 71.28 7.92 53.1 8.05 ...
##  $ Cabin      : chr  "" "C85" "" "C123" ...
##  $ Embarked   : Factor w/ 4 levels "","C","Q","S": 4 2 4 4 4 3 4 4 4 2 ...
```

Con el objetivo de ver si es posible descartar alguna de las variables numéricas, procedemos a aplicar un análisis de componentes principales. Mediante esta técnica se puede detectar qué variables aportan un porcentaje de varianza mayor y son, por tanto, más significativas.

```
# Se omite la variable passengerId porque representa un identificador de cada observación
# y no una característica real de cada pasajero
titanic.pca <- prcomp(na.omit(select(titanicData,c("Age", "SibSp", "Parch", "Fare"))),
                      center=TRUE, scale=TRUE)
summary(titanic.pca)
```

```
## Importance of components:
##                           PC1    PC2    PC3    PC4
## Standard deviation     1.2510 1.0912 0.7968 0.7807
## Proportion of Variance 0.3912 0.2977 0.1587 0.1524
## Cumulative Proportion  0.3912 0.6889 0.8476 1.0000
```

Aunque los dos primeros componentes contribuyen a una mayor proporción de varianza (casi un 70 %), los dos restantes aportan un porcentaje lo suficientemente elevado (algo más del 30 %) y parejo entre sí, como para tomar la decisión de mantener todas las variables en la construcción del modelo.

No obstante, es probable que tras un estudio más detallado de los datos en los siguientes apartados, se decida eliminar algún atributo más. Además, se podrán descartar puntualmente variables en la aplicación de alguna de las técnicas estadísticas del análisis, ya sea para mejorar su desempeño o por incompatibilidad del tipo de dato con el algoritmo en uso.

Reducción de cantidad

Dado que el número de registros del data frame no es muy elevado, no se plantea una reducción de la cantidad de registros.

Limpieza de los datos

Como paso previo a la aplicación de cualquier técnica de análisis de datos, es preciso revisar el *dataset* suministrado con el objetivo de encontrar errores e incongruencias y homogeneizar el contenido de las variables que lo conforman.

Mediante la función summary visualizamos un resumen completo de los datos:

- Para las variables cuantitativas, se muestran los valores mínimos/máximos, la media, la mediana y los cuartiles primero y tercero.
- Para las variables cualitativas definidas como factores, la frecuencia de valores por categoría.

```
# Resumen de las variables del dataset
summary(titanicData)
```

```
##   PassengerId   Survived Pclass      Sex           Age
##  Min.   :   1   No:815   1:323   female:466   Min.   : 0.17
##  1st Qu.: 328   Si:494   2:277   male  :843   1st Qu.:21.00
##  Median : 655            3:709                Median :28.00
##  Mean   : 655                                 Mean   :29.88
##  3rd Qu.: 982                                 3rd Qu.:39.00
##  Max.   :1309                                 Max.   :80.00
##                                               NA's   :263
##      SibSp            Parch          Ticket               Fare
##  Min.   :0.0000   Min.   :0.000   Length:1309        Min.   :  0.000
##  1st Qu.:0.0000   1st Qu.:0.000   Class :character   1st Qu.:  7.896
##  Median :0.0000   Median :0.000   Mode  :character   Median : 14.454
##  Mean   :0.4989   Mean   :0.385                      Mean   : 33.295
##  3rd Qu.:1.0000   3rd Qu.:0.000                      3rd Qu.: 31.275
##  Max.   :8.0000   Max.   :9.000                      Max.   :512.329
##                                                      NA's   :1
##     Cabin           Embarked
##  Length:1309         :  2
##  Class :character   C:270
##  Mode  :character   Q:123
##                     S:914
##
##
##
```

Con esta breve revisión ya pueden apreciarse varios aspectos que deben tratarse antes de iniciar cualquier proceso analítico como, por ejemplo, la existencia de valores perdidos (NA's) en algunas de las variables (Age y Fare) y de valores vacíos (Embarked). También llaman la atención algunos valores encontrados en las variables numéricas, como los valores mínimo (0) y máximo (512.3292) de Fare, éste último muy alejado de la mediana.

Tratamiento de elementos vacíos y ceros

Revisión de los datos

Comprobamos el total de datos que presentan valores vacíos (NA y no informados) y a cero por variable:

```
# Número de observaciones con valores NA
cat("\nNúmero de observaciones con valores NA\n")
```

```
##
## Número de observaciones con valores NA
```

```
colSums(is.na(titanicData))
```

```
## PassengerId    Survived      Pclass         Sex         Age       SibSp
##           0           0           0           0         263           0
##       Parch      Ticket        Fare       Cabin    Embarked
##           0           0           1           0           0
```

```
# Número de observaciones con valores vacíos
cat("\nNúmero de observaciones con valores vacíos\n")
```

```
##
## Número de observaciones con valores vacíos
```

```
colSums(titanicData=="", na.rm=TRUE)
```

```
## PassengerId    Survived      Pclass         Sex         Age       SibSp
##           0           0           0           0           0           0
##       Parch      Ticket        Fare       Cabin    Embarked
##           0           0           0        1014           2
```

```
# Número de registros con ceros
cat("\nNúmero de registros con ceros\n")
```

```
##
## Número de registros con ceros
```

```
colSums(titanicData==0, na.rm=TRUE)
```

```
## PassengerId    Survived      Pclass         Sex         Age       SibSp
##           0           0           0           0           0         891
##       Parch      Ticket        Fare       Cabin    Embarked
##        1002           0          17           0           0
```

Hay valores a cero en las variables numéricas SibSp, Parch y Fare. En las dos primeras (número de hermanos/cónyuges y número de padres/hijos) este valor es razonable y se asumirán estos valores como correctos. En cuanto a Fare (coste del pasaje) es, a priori, extraño que ciertos billetes no tuviesen coste alguno, y, aunque podrían ser valores correctos (por ejemplo, podrían ser invitaciones al viaje inaugural), se estudiarán a continuación con más detalle.

Tratamiento

Valores vacíos

En el caso de la variable Cabin, el porcentaje de valores vacíos es demasiado alto (77.46 %) como para poder extrapolarlo o que resulte útil en el estudio, por lo que se decide descartar esta variable.

```
# Se descarta la variable Cabin
titanicData <- select(titanicData, -c(Cabin))

# Se visualizan los primeros registros para comprobar la eliminación realizada
kable(head(titanicData)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked
1	No	3	male	22	1	0	A/5 21171	7.2500	S
2	Si	1	female	38	1	0	PC 17599	71.2833	C
3	Si	3	female	26	0	0	STON/O2. 3101282	7.9250	S
4	Si	1	female	35	1	0	113803	53.1000	S
5	No	3	male	35	0	0	373450	8.0500	S
6	No	3	male	NA	0	0	330877	8.4583	Q

Para el caso de los dos registros con valores vacíos encontrados en Embarked, se van a sustituir por valores NA y serán tratados posteriormente haciendo uso del algoritmo kNN para su imputación.

```
# Se sustituyen los valores vacíos por el valor NA
titanicData$Embarked[titanicData$Embarked==""] <- NA
```

Valores igual a cero

Revisamos qué registros son los que tienen el importe de Fare a 0.

```
# Se visualizan los casos en los que el valor del billete es igual a cero
filter(titanicData, Fare==0)
```

```
##    PassengerId Survived Pclass  Sex Age SibSp Parch Ticket Fare Embarked
## 1          180       No      3 male  36     0     0   LINE    0        S
## 2          264       No      1 male  40     0     0 112059    0        S
## 3          272       Si      3 male  25     0     0   LINE    0        S
## 4          278       No      2 male  NA     0     0 239853    0        S
## 5          303       No      3 male  19     0     0   LINE    0        S
## 6          414       No      2 male  NA     0     0 239853    0        S
## 7          467       No      2 male  NA     0     0 239853    0        S
## 8          482       No      2 male  NA     0     0 239854    0        S
## 9          598       No      3 male  49     0     0   LINE    0        S
## 10         634       No      1 male  NA     0     0 112052    0        S
## 11         675       No      2 male  NA     0     0 239856    0        S
## 12         733       No      2 male  NA     0     0 239855    0        S
## 13         807       No      1 male  39     0     0 112050    0        S
## 14         816       No      1 male  NA     0     0 112058    0        S
## 15         823       No      1 male  38     0     0  19972    0        S
## 16        1158       No      1 male  NA     0     0 112051    0        S
## 17        1264       No      1 male  49     0     0 112058    0        S
```

No parece apreciarse ningún patrón o característica específica en las observaciones mostradas: parece poco probable que el valor de 0 sea correcto (que se deba, por ejemplo, a invitaciones al viaje inaugural, puesto que hay varias en tercera clase), por lo que se va a proceder a sustituir estos valores perdidos con valores NA para ser tratados junto con el resto de valores perdidos con el algoritmo kNN.

```
# Se sustituyen los valores vacíos por el valor NA
titanicData$Fare[titanicData$Fare==0] <- NA
```

Valores NAs

Para los valores NA existentes en las variables Embarked, Age y Fare, se va a usar la técnica kNN (por sus siglas en inglés, k-Nearest Neighbours), que permite predecir valores en conjuntos de datos multidimensionales formados por datos mixtos (continuos, discretos, ordinales y/o nominales). Este algoritmo encuentra los k vecinos más cercanos y, dependiendo de la variable a imputar, aplica uno de los dos criterios siguientes:

- Si es cualitativa, le asignará el valor más frecuente.
- Si es cuantitativa, le dará el valor de la mediana.

Se comprueba el número de valores NA:

```
# Se comprueba el número de valores NA por variable y se muestran gráficamente
summary(aggr(titanicData, numbers=TRUE))
```

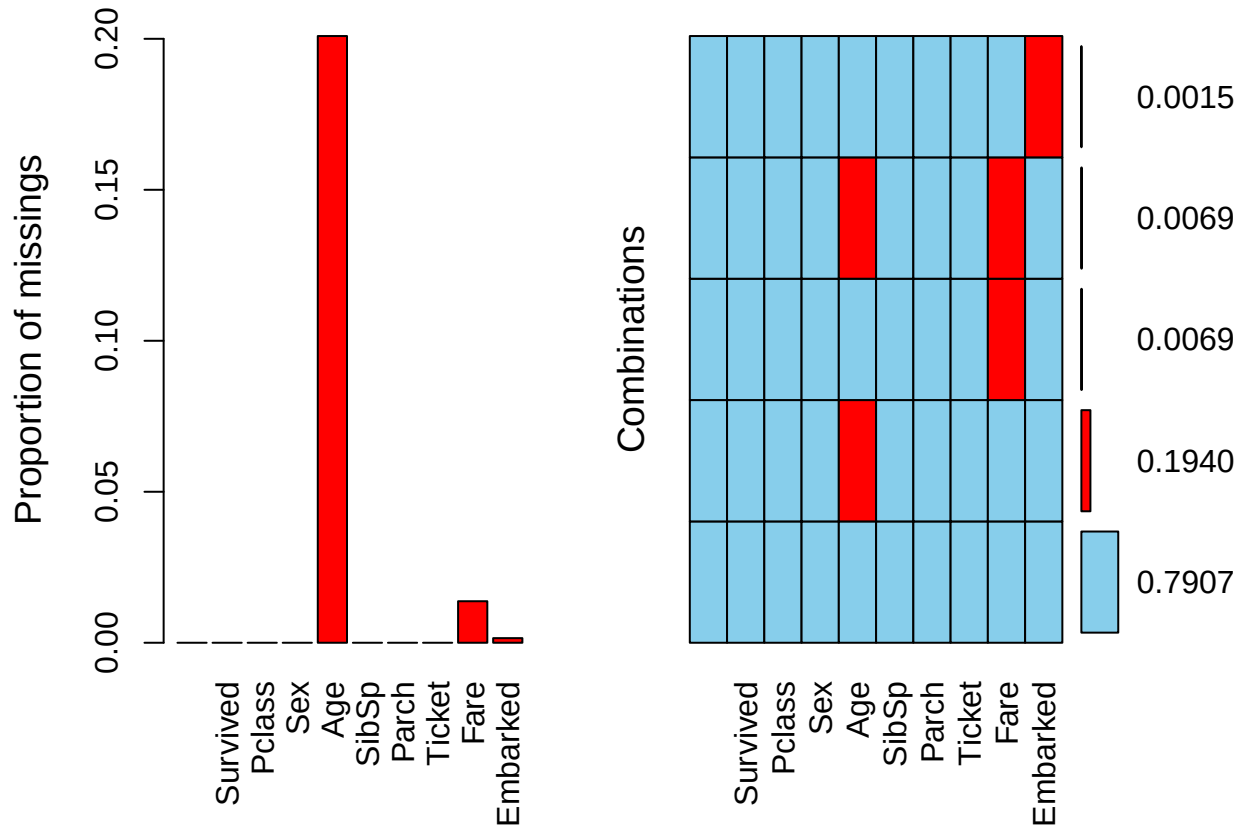


```
##
##  Missings per variable:
##     Variable Count
##  PassengerId     0
##     Survived     0
##       Pclass     0
##          Sex     0
##          Age   263
##        SibSp     0
##        Parch     0
##       Ticket     0
##         Fare    18
##     Embarked     2
##
##  Missings in combinations of variables:
##         Combinations Count    Percent
##  0:0:0:0:0:0:0:0:0:0  1035 79.0679908
##  0:0:0:0:0:0:0:0:0:1     2  0.1527884
##  0:0:0:0:0:0:0:0:1:0     9  0.6875477
##  0:0:0:0:1:0:0:0:0:0   254 19.4041253
##  0:0:0:0:1:0:0:0:1:0     9  0.6875477
```

Como puede observarse, la variable con mayor cantidad de valores perdidos es Age, con 263 registros

(aproximadamente un 20 % del total) sin informar. En la gráfica de la derecha se muestran las combinaciones de variables perdidas. Un 79 % de las observaciones tienen todas sus variables informadas, y sólo un 0,7 % tienen más de un valor perdido (Fare y Age).

Se procede a realizar la imputación:

```
# Se aplica kNN con el valor de k por defecto, 5, e indicando que no es preciso generar
# las variables informativas de imputación
titanicData <- VIM::kNN(titanicData, imp_var=FALSE)

# Se comprueba que ya no hay valores NA
colSums(is.na(titanicData))
```

```
## PassengerId    Survived      Pclass         Sex         Age       SibSp
##           0           0           0           0           0           0
##       Parch      Ticket        Fare    Embarked
##           0           0           0           0
```

Se vuelven a establecer los niveles de la variable Embarked, ahora ya con sólo tres categorías correspondientes a los tres puertos de embarque:

```
# Se establecen los factores omitiendo el factor NA
titanicData$Embarked <- factor(titanicData$Embarked, levels=c("C","Q","S"))

# Se comprueban los factores y la distribución de valores
levels(titanicData$Embarked)
```

```
## [1] "C" "Q" "S"
```

```
summary(titanicData$Embarked)
```

```
##   C   Q   S
## 270 123 916
```

Tratamiento de valores extremos

Procedemos a revisar mediante gráficos de cajas y bigotes posibles valores extremos de las variables.

```
# Boxplot de Age
boxplot(titanicData$Age, main="Edad", col="steelblue2")
```

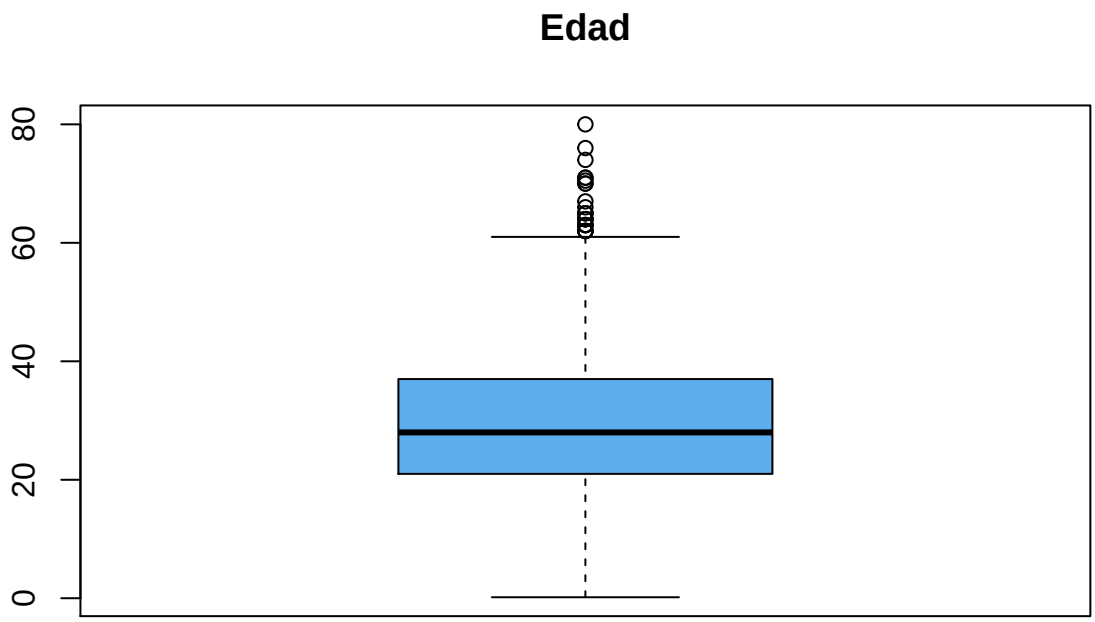


```
# Mostramos los valores extremos mediante las estadísticas del gráfico
boxplot.stats(titanicData$Age)$out
```

```
##  [1] 66.0 65.0 71.0 70.5 62.0 63.0 65.0 64.0 65.0 63.0 71.0 64.0 62.0 62.0
## [15] 80.0 70.0 70.0 62.0 74.0 62.0 63.0 67.0 76.0 63.0 64.0 64.0 64.0
```

Dentro de la variable edad se han detectado varios valores considerados extremos pero, tras revisarlos, se comprueba que entran dentro de un rango válido para la edad, por lo que se consideran correctos y no se realizará ningún tratamiento adicional.

```
# Boxplot de SibSp
boxplot(titanicData$SibSp, main="Número de hermanos/cónyuges", col="steelblue2")
```

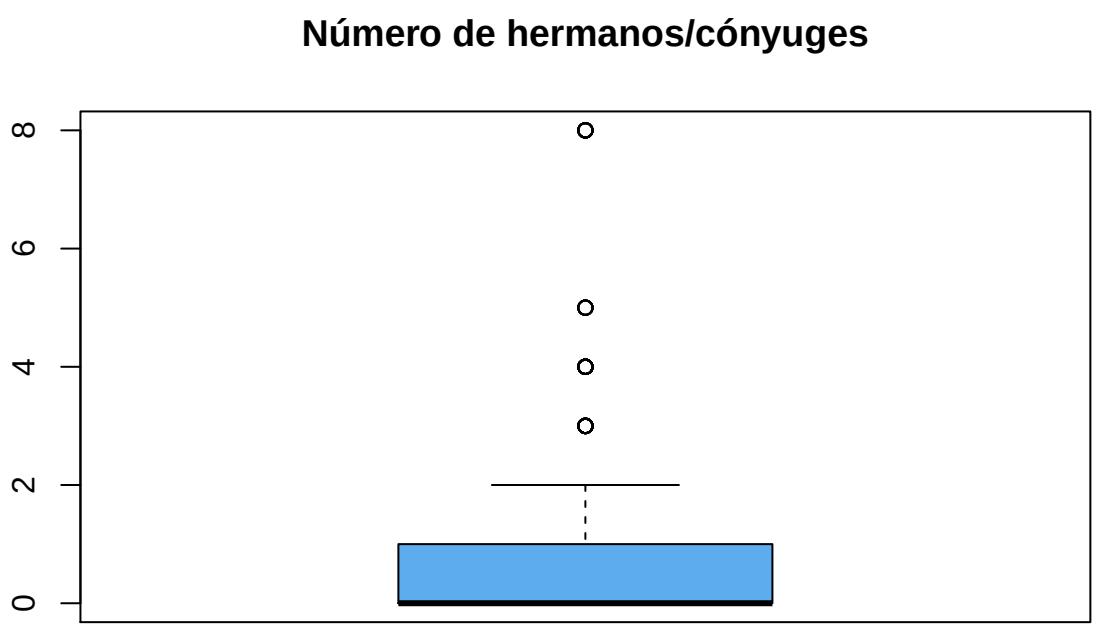


```
# Mostramos los valores extremos
boxplot.stats(titanicData$SibSp)$out
```

```
##  [1] 3 4 3 3 4 5 3 4 5 3 3 4 8 4 4 3 8 4 8 3 4 4 4 4 8 3 3 5 3 5 3 4 4 3 3
## [36] 5 4 3 4 8 4 3 4 8 4 8 3 4 5 3 4 8 4 8 4 3 3
```

Esta variable recoge el número de hermanos o cónyuges de cada pasajero y, como en el caso anterior, aunque se detectan varios valores extremos, parecen razonables y por tanto no se realizará acción alguna sobre ellos.

```
# Boxplot de Parch
boxplot(titanicData$Parch, main="Número de padres/hijos", col="steelblue2")
```

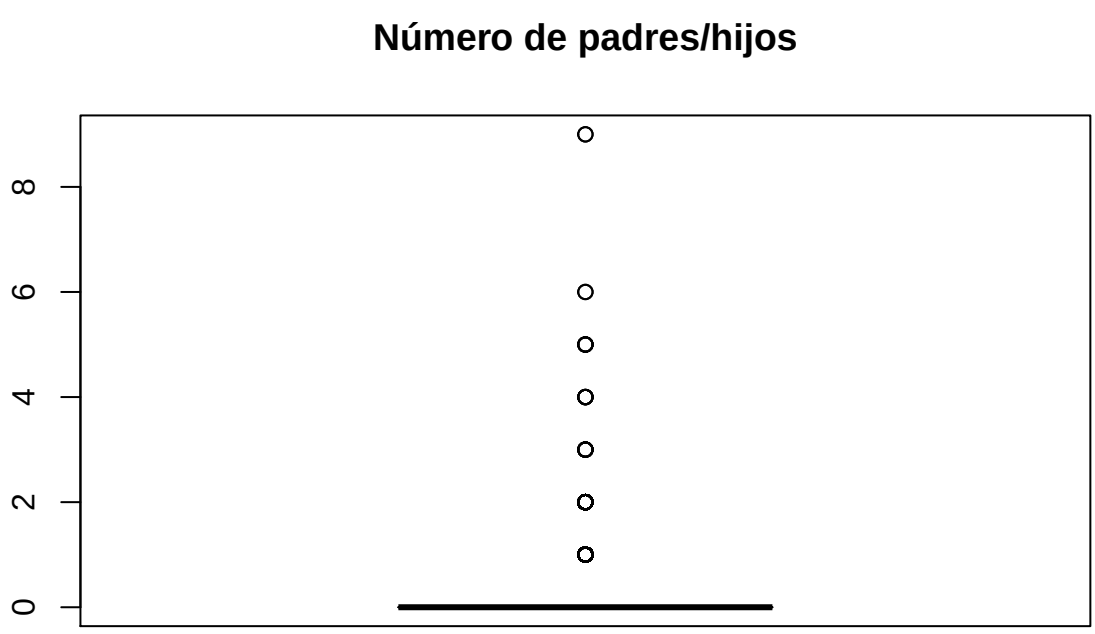


```
# Mostramos los valores extremos
boxplot.stats(titanicData$Parch)$out
```

```
##   [1] 1 2 1 5 1 1 5 2 2 1 1 2 2 2 1 2 2 2 3 2 2 1 1 1 1 2 1 1 2 2 1 2 2 2 1
##  [36] 2 1 1 2 1 4 1 1 1 1 2 2 1 2 1 1 1 2 1 1 2 2 2 1 1 2 2 1 2 1 1 1 1 1 1
##  [71] 1 2 1 2 2 1 1 2 1 1 2 1 1 1 1 2 1 1 1 4 1 1 2 2 2 2 2 1 1 1 2 2 1 1 2
## [106] 2 3 4 1 2 1 1 2 1 2 1 2 1 1 2 2 1 1 1 1 2 2 2 2 2 2 1 1 2 1 4 1 1 2 1
## [141] 2 1 1 2 5 2 1 1 1 2 1 5 2 1 1 1 2 1 6 1 2 1 2 1 1 1 1 1 1 1 3 2 1 1 1
## [176] 1 2 1 2 3 1 2 1 2 2 1 1 2 1 2 1 2 1 1 1 2 1 1 2 1 2 1 1 1 1 3 2 1 1 1
## [211] 1 5 2 1 1 1 1 3 1 2 2 1 2 1 2 1 2 4 1 1 2 1 1 1 4 6 2 3 1 1 2 2 2 1 1
## [246] 2 5 2 3 2 1 1 1 2 1 2 2 2 1 2 1 1 2 1 2 1 2 1 2 2 1 1 1 1 2 1 1 2 1
## [281] 1 1 2 1 2 9 1 1 1 2 2 2 1 9 1 1 2 2 1 1 2 1 1 1 1 1 1
```

Esta variable representa el número de hijos o padres. Los valores mostrados también están dentro de un rango razonable y no es posible determinar si alguno de ellos es erróneo, por lo que tampoco se aplicará tratamiento alguno.

```
# Boxplot de Fare
boxplot(titanicData$Fare, main="Tarifa del pasaje", col="steelblue2")
```

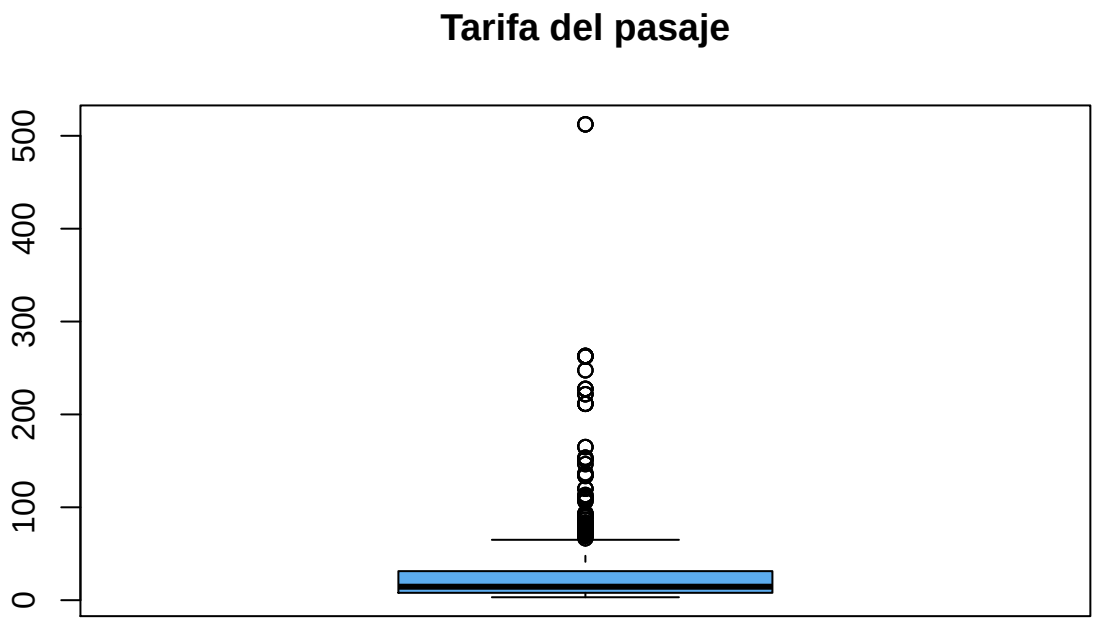


```
# Mostramos los valores extremos utilizando las estadísticas de $out
boxplot.stats(titanicData$Fare)$out
```

```
##   [1]  71.2833 263.0000 146.5208  82.1708  76.7292  80.0000  83.4750
##   [8]  73.5000 263.0000  77.2875 247.5208  73.5000  77.2875  79.2000
##  [15]  66.6000  69.5500  69.5500 146.5208  69.5500 113.2750  76.2917
##  [22]  90.0000  83.4750  90.0000  79.2000  86.5000 512.3292  79.6500
##  [29] 153.4625 135.6333  77.9583  78.8500  91.0792 151.5500 247.5208
##  [36] 151.5500 110.8833 108.9000  83.1583 262.3750 164.8667 134.5000
##  [43]  69.5500 135.6333 153.4625 133.6500  66.6000 134.5000 263.0000
##  [50]  75.2500  69.3000 135.6333  82.1708 211.5000 227.5250  73.5000
##  [57] 120.0000 113.2750  90.0000 120.0000 263.0000  81.8583  89.1042
##  [64]  91.0792  90.0000  78.2667 151.5500  86.5000 108.9000  93.5000
##  [71] 221.7792 106.4250  71.0000 106.4250 110.8833 227.5250  79.6500
##  [78] 110.8833  79.6500  79.2000  78.2667 153.4625  77.9583  69.3000
##  [85]  76.7292  73.5000 113.2750 133.6500  73.5000 512.3292  76.7292
##  [92] 211.3375 110.8833 227.5250 151.5500 227.5250 211.3375 512.3292
##  [99]  78.8500 262.3750  71.0000  86.5000 120.0000  77.9583 211.3375
## [106]  79.2000  69.5500 120.0000  93.5000  80.0000  83.1583  69.5500
## [113]  89.1042 164.8667  69.5500  83.1583  82.2667 262.3750  76.2917
## [120] 263.0000 262.3750 262.3750 263.0000 211.5000 211.5000 221.7792
## [127]  78.8500 221.7792  75.2417 151.5500 262.3750  83.1583 221.7792
## [134]  83.1583  83.1583 247.5208  69.5500 134.5000 227.5250  73.5000
## [141] 164.8667 211.5000  71.2833  75.2500 106.4250 134.5000 136.7792
## [148]  75.2417 136.7792  82.2667  81.8583 151.5500  93.5000 135.6333
## [155] 146.5208 211.3375  79.2000  69.5500 512.3292  73.5000  69.5500
```

```
## [162]  69.5500 134.5000  81.8583 262.3750  93.5000  79.2000 164.8667
## [169] 211.5000  90.0000 108.9000
```

Esta variable recoge el precio del pasaje. Sobresale especialmente el importe máximo (superior a 500) por su diferencia con el siguiente valor (alrededor de 200). Mostramos estos registros para intentar deducir si se trata de una errata o su valor es correcto:

```
# Revisamos los registros con mayor valor
kable(filter(titanicData, Fare>500)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked
259	Si	1	female	35	0	0	PC 17755	512.3292	C
680	Si	1	male	36	0	1	PC 17755	512.3292	C
738	Si	1	male	35	0	0	PC 17755	512.3292	C
1235	Si	1	female	58	0	1	PC 17755	512.3292	C

Las cuatro observaciones con el valor máximo corresponden al mismo ticket, por lo que se puede concluir o que ese ticket en concreto fue mal registrado o que es un valor válido y se trata de un pasaje VIP. Tras revisar documentación externa especializada (*Traveler*, 2016) sobre el coste de los billetes en el Titanic y constatar que entran dentro del rango de valores posibles, se determina que son válidos.

Discretización

Ciertos métodos estadísticos requieren u obtienen un mejor desempeño utilizando variables discretas en lugar de continuas. Por ello, se va a proceder a crear nuevas variables que agrupen en distintos grupos los siguientes atributos: Age, Fare, SibSp y Parch.

```
# Discretización para edad
titanicData$AgeD <- cut(titanicData$Age, c(0, 16, 60, 90),
                        labels=c("kid", "adult", "elder"),
                        include.lowest=TRUE, right=FALSE)

# Discretización para tarifa del pasaje
titanicData$FareD <- cut(titanicData$Fare, c(0, 9, 33, 520),
                         labels=c("low", "medium", "high"),
                         include.lowest=TRUE, right=FALSE)

# Discretización para número de hermanos/cónyuges
titanicData$SibSpD <- cut(titanicData$SibSp, c(0, 1, 4, 10),
                          labels=c("none", "few", "many"),
                          include.lowest=TRUE, right=FALSE)

# Discretización para número de padres/hijos
titanicData$ParchD <- cut(titanicData$Parch, c(0, 1, 4, 10),
                          labels=c("none", "few", "many"),
                          include.lowest=TRUE, right=FALSE)

# Se visualizan algunos datos para comprobar el contenido de las nuevas variables
kable(head(titanicData)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked	AgeD	FareD	SibSpD	ParchD
1	No	3	male	22	1	0	A/5 21171	7.2500	S	adult	low	few	none
2	Si	1	female	38	1	0	PC 17599	71.2833	C	adult	high	few	none
3	Si	3	female	26	0	0	STON/O2. 3101282	7.9250	S	adult	low	none	none
4	Si	1	female	35	1	0	113803	53.1000	S	adult	high	few	none
5	No	3	male	35	0	0	373450	8.0500	S	adult	low	none	none
6	No	3	male	21	0	0	330877	8.4583	Q	adult	low	none	none

```r
# Se revisa que se hayan creado como factores
str(titanicData)
```

```
## 'data.frame':    1309 obs. of  14 variables:
##  $ PassengerId: int  1 2 3 4 5 6 7 8 9 10 ...
##  $ Survived   : Factor w/ 2 levels "No","Si": 1 2 2 2 1 1 1 1 2 2 ...
##  $ Pclass     : Factor w/ 3 levels "1","2","3": 3 1 3 1 3 3 1 3 3 2 ...
##  $ Sex        : Factor w/ 2 levels "female","male": 2 1 1 1 2 2 2 2 1 1 ...
##  $ Age        : num  22 38 26 35 35 21 54 2 27 14 ...
##  $ SibSp      : int  1 1 0 1 0 0 0 3 0 1 ...
##  $ Parch      : int  0 0 0 0 0 0 0 1 2 0 ...
##  $ Ticket     : chr  "A/5 21171" "PC 17599" "STON/O2. 3101282" "113803" ...
##  $ Fare       : num  7.25 71.28 7.92 53.1 8.05 ...
##  $ Embarked   : Factor w/ 3 levels "C","Q","S": 3 1 3 3 3 2 3 3 3 1 ...
##  $ AgeD       : Factor w/ 3 levels "kid","adult",..: 2 2 2 2 2 2 2 1 2 1 ...
##  $ FareD      : Factor w/ 3 levels "low","medium",..: 1 3 1 3 1 1 3 2 2 2 ...
##  $ SibSpD     : Factor w/ 3 levels "none","few","many": 2 2 1 2 1 1 1 2 1 2 ...
##  $ ParchD     : Factor w/ 3 levels "none","few","many": 1 1 1 1 1 1 1 2 2 1 ...
```

Análisis de los datos

Análisis descriptivo visual

Previo al análisis detallado de los datos y a la elaboración de los tests estadísticos, es importante realizar un primer análisis visual de los mismos para conocer mejor sus características y distribución de valores.

Para las variables cualitativas o categóricas, se utilizarán diagramas de barras o de sectores. Para las variables cuantitativas, además de los diagramas de cajas que ya han sido empleados en el apartado de valores extremos, se emplearán histogramas. Se realizará además un estudio visual sobre posibles relaciones entre variables con el objetivo de eliminar posibles redundancias.

Variable Survived

Esta variable representa si el pasajero sobrevivió (valor "Si") o no (valor "No") al hundimiento del Titanic. Es la variable que se pretende explicar o predecir a partir del resto.

Como puede observarse a continuación, el número de pasajeros que fallecieron fue muy elevado, casi dos tercios del total.

```r
# Se muestra la tabla de frecuencias
table(titanicData$Survived)
```

```
##
##  No  Si
## 815 494
```

```r
# Se genera una gráfica de tarta
# Nombres y porcentajes de los sectores
pieNames <- names(table(titanicData$Survived))
piePerc <- round(prop.table(table(titanicData$Survived))*100, 2)

# Incorporamos a la etiqueta del gráfico los nombres y porcentajes de cada categoría
pieLabels <- paste(pieNames, "\n", piePerc, "%")

pie(table(titanicData$Survived), labels=pieLabels, main="Pasajeros que sobrevivieron",
    col=brewer.pal(2, "Blues"))
```

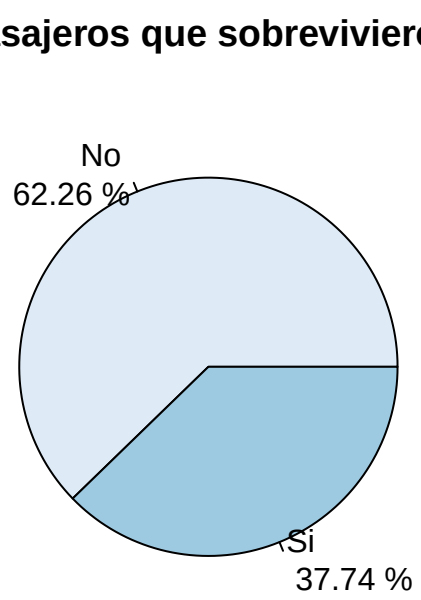

Variable Pclass

Esta variable representa la clase en la que viaja cada pasajero. Más de la mitad lo hacían en tercera clase, mientras que la proporción entre primera y segunda está más equilibrada.

```
# Se muestra la tabla de frecuencias
pclassTable <- table(titanicData$Pclass)
rownames(pclassTable) <- c("Primera", "Segunda", "Tercera")
pclassTable
```

```
##
## Primera Segunda Tercera
##     323     277     709
```

```
# Se genera una gráfica de tarta
# Nombres y porcentajes de los sectores
pieNames <- names(pclassTable)
piePerc <- round(prop.table(pclassTable)*100, 2)

# Incorporamos a la etiqueta del gráfico los nombres y porcentajes de cada categoría
pieLabels <- paste(pieNames, "\n", piePerc, "%")

pie(pclassTable, labels=pieLabels, main="Clase del pasaje",
    col=brewer.pal(3, "Blues"))
```

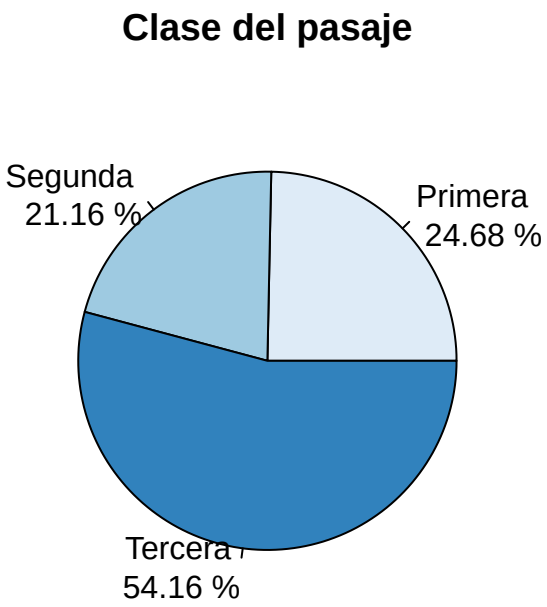

Variable Sex

En cuanto a la distribución por sexos, según puede observarse en el gráfico siguiente, predominaban los hombres, constituyendo casi dos terceras partes de los pasajeros.

```
# Se muestra la tabla de frecuencias
sexTable <- table(titanicData$Sex)
rownames(sexTable) <- c("Mujer", "Hombre")
sexTable
```

```
##
##  Mujer Hombre
##    466    843
```

```
# Se genera una gráfica de tarta
# Nombres y porcentajes de los sectores
pieNames <- names(sexTable)
piePerc <- round(prop.table(sexTable)*100, 2)

# Incorporamos a la etiqueta del gráfico los nombres y porcentajes de cada categoría
pieLabels <- paste(pieNames, "\n", piePerc, "%")

pie(sexTable, labels=pieLabels, main="Sexo",
    col=brewer.pal(3, "Blues"))
```

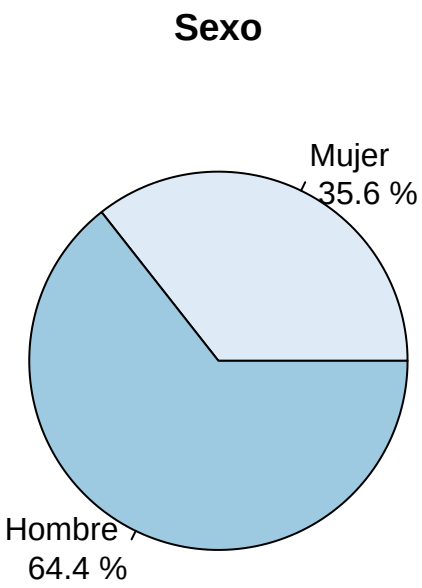

Variable Age

Respecto a la edad, vemos que hay una acumulación de observaciones alrededor de edades intermedias (entre los 20 y 40 años aproximadamente). También puede observarse un sesgo a la derecha, hacia edades superiores.

```
# Resumen de los valores de Age
summary(titanicData$Age)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.17   21.00   28.00   29.58   37.00   80.00
```

```
# Se genera el histograma, estableciendo un ancho de barras de 5 años
ggplot(data=titanicData, aes(x=Age, fill=Age)) +
  geom_histogram(binwidth=5, color="darkblue", fill="lightblue") +
  labs(x="Edad", y="Frecuencia")
```

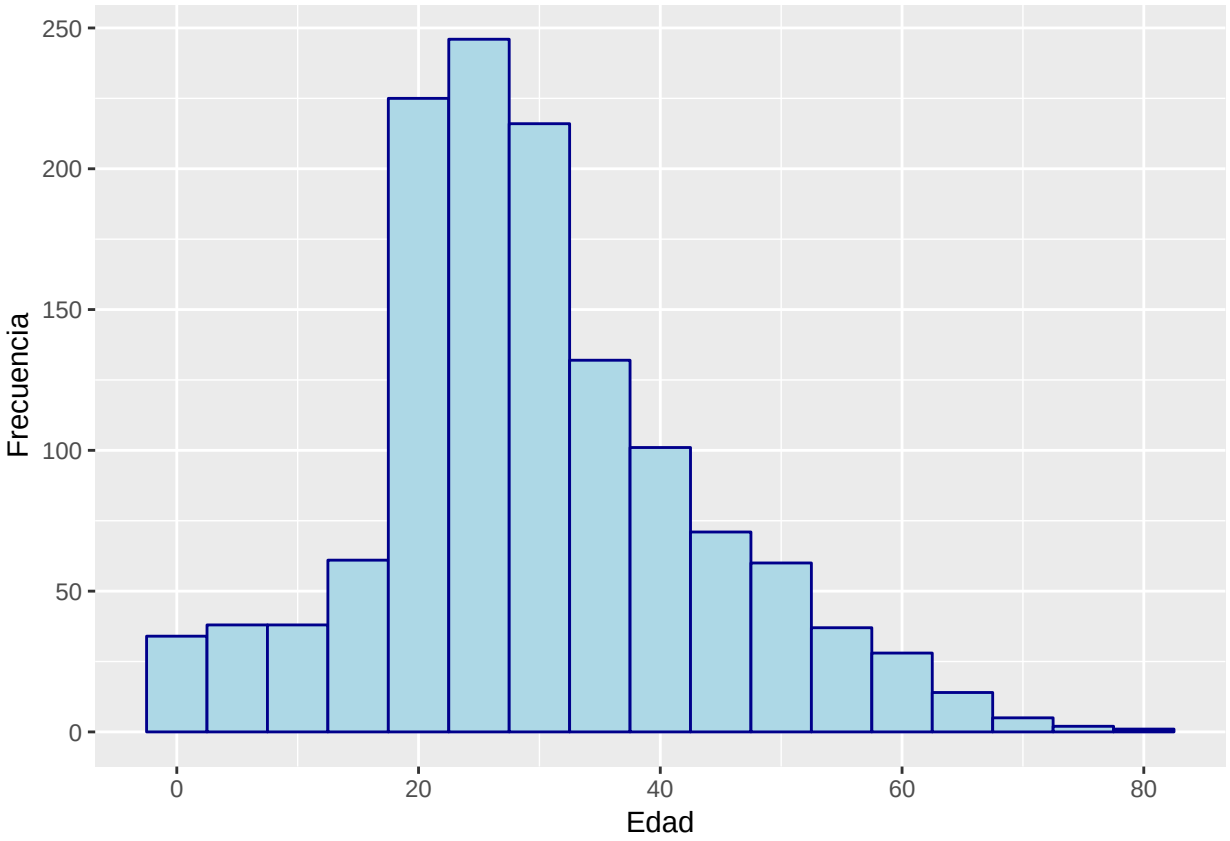

Variable SibSp

Esta variable indica el número de hermanos y/o cónyuges de los pasajeros. Puede observarse en el gráfico una proporción elevada de personas que viajan sin hermanos ni esposos y el valor atípico que ya habíamos detectado previamente de 8, claramente separado del resto.

```
# Resumen de los valores de SibSp
summary(titanicData$SibSp)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  0.0000  0.0000  0.0000  0.4989  1.0000  8.0000
```

```
# Se genera el gráfico de barras
ggplot(data=titanicData, aes(x=SibSp, fill=SibSp)) +
  geom_bar(color="darkblue", fill="lightblue") +
  labs(x="Número de hermanos/cónyuges", y="Frecuencia")
```

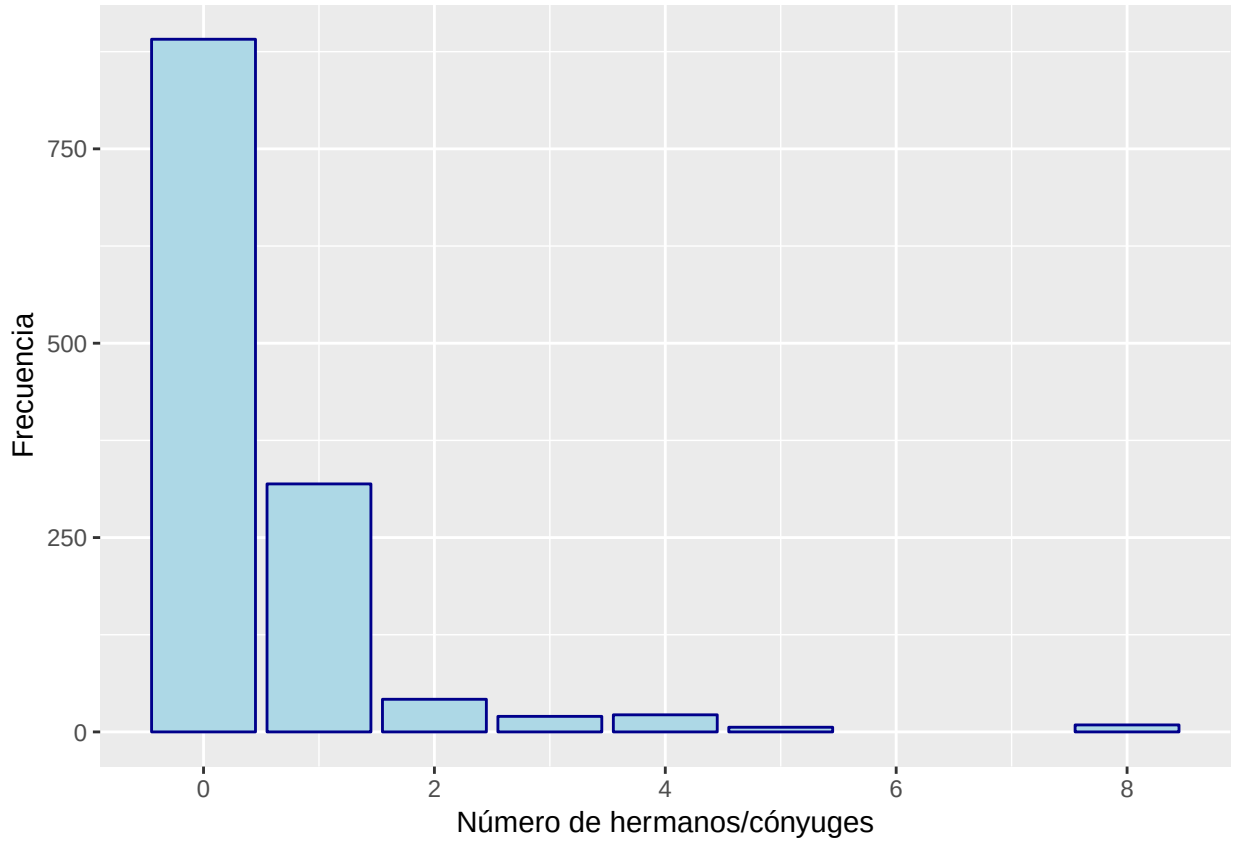

Variable Parch

Con esta variable se indica el número de padres e hijos de los pasajeros. Puede apreciarse, de manera análoga al caso anterior, que también hay una gran proporción de viajeros que viajaban solos (sin ascendencia/descendencia). También se observa el valor extremo de 9 aislado a la derecha de la grafica.

```
# Resumen de los valores de Parch
summary(titanicData$Parch)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   0.000   0.000   0.000   0.385   0.000   9.000
```

```
# Se genera el histograma
ggplot(data=titanicData, aes(x=Parch, fill=Parch)) +
  geom_bar(color="darkblue", fill="lightblue") +
  labs(x="Número de padres/hijos", y="Frecuencia")
```

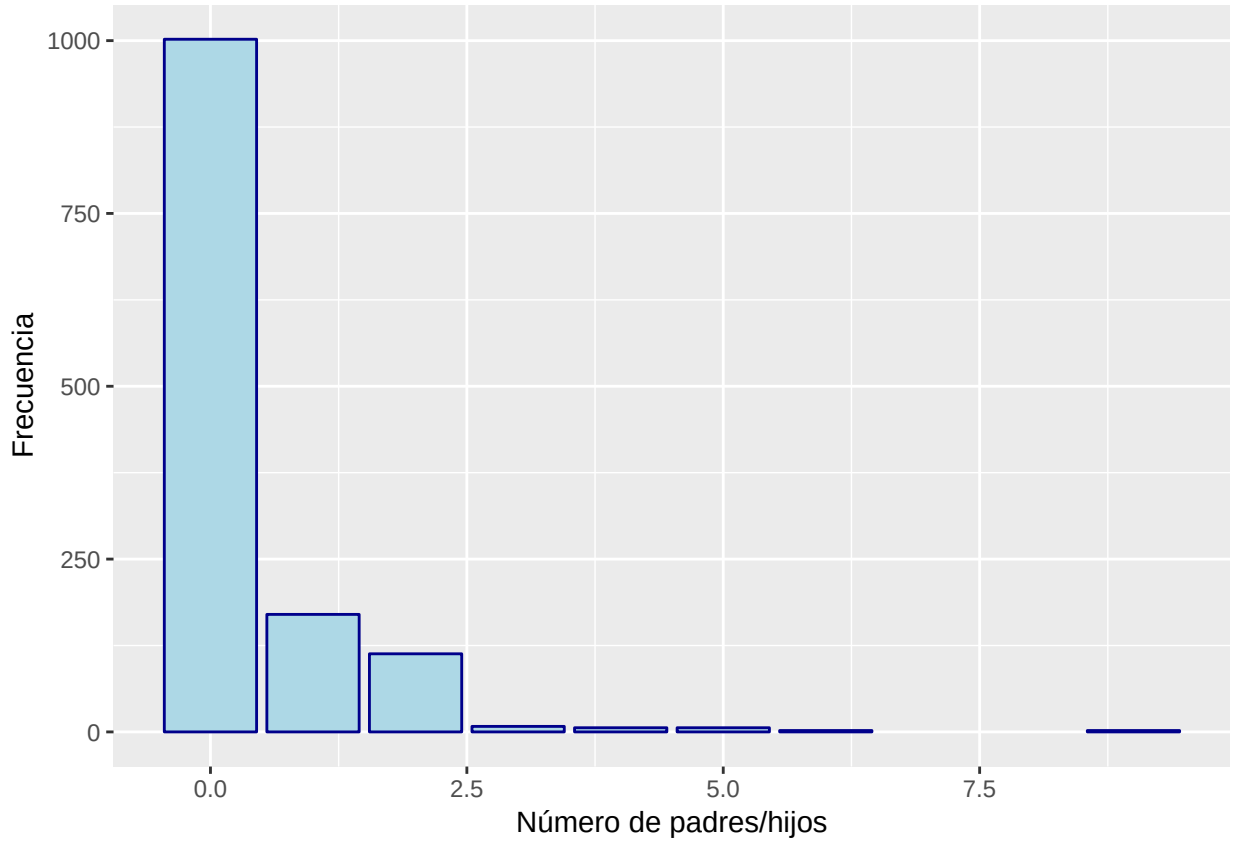

Variable Fare

Esta variable representa el precio del pasaje. Aunque hay un rango de precios muy amplio, un 75 % de los valores se concentra en la franja igual o inferior a 65 (ver boxplot para más detalles).

```
# Resumen de los valores de Fare
summary(titanicData$Fare)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   3.171   7.925  14.500  33.526  31.275 512.329
```

```
# Se genera el histograma, estableciendo un ancho de barras de 15
ggplot(data=titanicData, aes(x=Fare, fill=Fare)) +
  geom_bar(binwidth=15, color="darkblue", fill="lightblue") +
  labs(x="Tarifa del pasaje", y="Frecuencia")
```

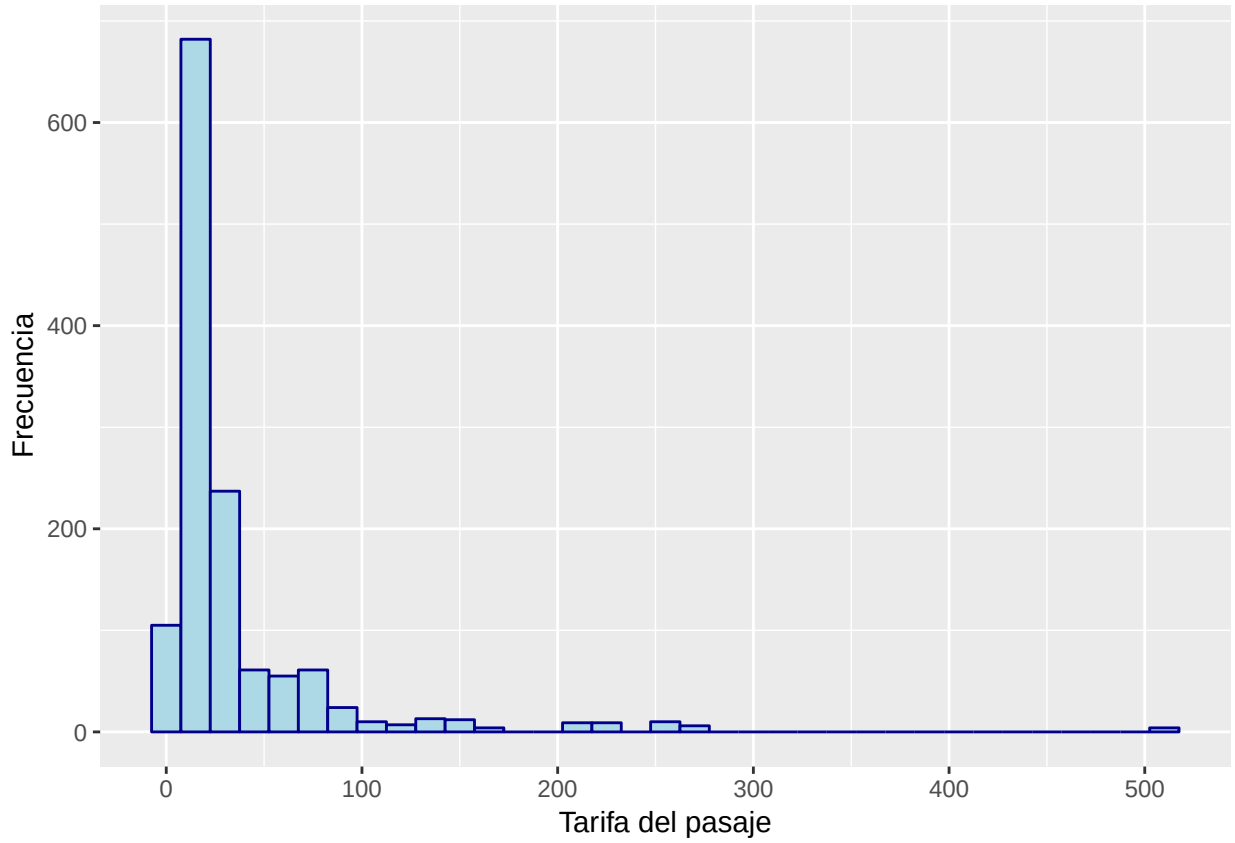

Variable Embarked

Esta variable identifica los tres puertos desde los que embarcaron los pasajeros. Según se aprecia en el gráfico de sectores, fue en Southampton donde se recogió la mayor parte de pasajeros.

```
# Se muestra la tabla de frecuencias
embarkedTable <- table(titanicData$Embarked)
rownames(embarkedTable) <- c("Cherbourg", "Queenstown", "Southampton")
embarkedTable
```

```
##
##   Cherbourg  Queenstown Southampton
##         270         123         916
```

```
# Se genera una gráfica de tarta
# Nombres y porcentajes de los sectores
pieNames <- names(embarkedTable)
piePerc <- round(prop.table(embarkedTable)*100, 2)

# Incorporamos a la etiqueta del gráfico los nombres y porcentajes de cada categoría
pieLabels <- paste(pieNames, "\n", piePerc, "%")

pie(embarkedTable, labels=pieLabels, main="Puerto de embarque",
    col=brewer.pal(3, "Blues"))
```

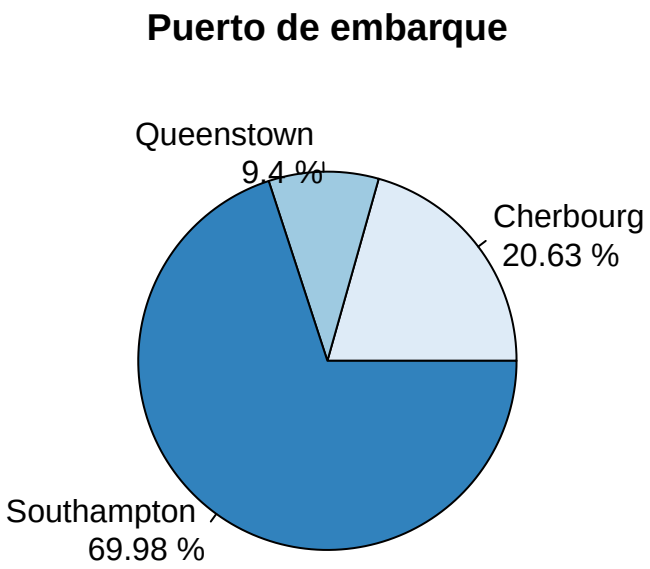

Correlación entre variables cuantitativas

Dada la influencia que las posibles relaciones entre variables pueden tener en la aplicación de tests estadísticos y la generación del modelo predictivo, vamos a realizar una matriz de correlación entre las variables numéricas existentes en el dataset.

El coeficiente de correlación de Pearson es uno de los más utilizados para identificar relaciones lineales entre variables, pero requiere que estas sigan una distribución normal y que sus varianzas sean iguales (homocedasticidad).

La visualización previa de estas variables mediante histogramas nos hace sospechar que no siguen una distribución normal, pero vamos a utilizar el test de **Shapiro-Wilk** para comprobarlo. En este test la hipótesis nula es que la variable sigue una distribución normal, frente a la hipótesis alternativa en la que la distribución no es normal.

```
# Tests sobre las variables numéricas
shapiro.test(titanicData$Age)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  titanicData$Age
## W = 0.97522, p-value = 3.28e-14
```

```
shapiro.test(titanicData$SibSp)
```

```
##
##  Shapiro-Wilk normality test
##
```

```
## data:  titanicData$SibSp
## W = 0.51108, p-value < 2.2e-16
```

```
shapiro.test(titanicData$Parch)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  titanicData$Parch
## W = 0.49797, p-value < 2.2e-16
```

```
shapiro.test(titanicData$Fare)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  titanicData$Fare
## W = 0.52316, p-value < 2.2e-16
```

En todos los tests realizados el p-valor es inferior a 0.05 (nivel de significación por defecto), por lo que no hay evidencia para aceptar la hipótesis nula. En consecuencia, asumimos que las variables **no siguen una distribución normal**. Por tanto, pasamos a aplicar el método de Spearman, test no paramétrico para obtener el grado de dependencia entre variables en las que no se dan los supuestos de normalidad y/o homocedasticidad.

```
# Se buscan posibles correlaciones entre variables numéricas
numData <- select(titanicData, c(PassengerId, Age, SibSp, Parch, Fare))

# Se calcula la matriz de correlación y se representa gráficamente
corMatrix <- cor(numData, method="spearman")
corMatrix
```

```
##              PassengerId         Age       SibSp        Parch         Fare
## PassengerId  1.000000000  0.01021112 -0.03229454 -0.006191346 -0.003889772
## Age          0.010211119  1.00000000 -0.13586186 -0.219468444  0.209006239
## SibSp       -0.032294543 -0.13586186  1.00000000  0.438372999  0.438382015
## Parch       -0.006191346 -0.21946844  0.43837300  1.000000000  0.395010451
## Fare        -0.003889772  0.20900624  0.43838202  0.395010451  1.000000000
```

```
corrplot(corMatrix)
```

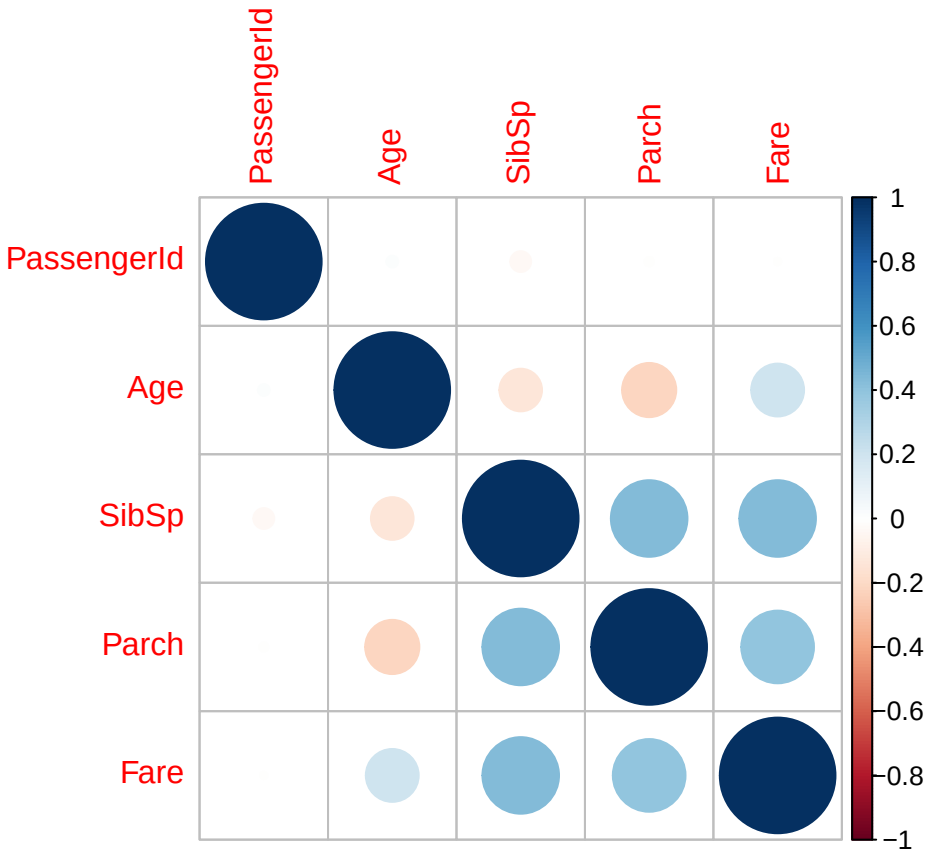

La variable PassengerID no tiene, como era de esperar, ninguna correlación con el resto. Esta variable es un identificador asignado a cada pasajero a posteriori, con el único objetivo de tener identificada cada una de las observaciones del dataset y por ello no formará parte como tal en la construcción del modelo.

Puede observarse cierta correlación entre las variables SibSp y Parch, así como entre SibSp y Fare, pero no en un grado que permita descartar inicialmente ninguna de ellas.

Relación de Survived con otras variables

A continuación comprobamos gráficamente si alguna de las variables explicativas cualitativas presentan algún tipo de relación con la variable dependiente. Esta información puede ayudarnos en la selección de variables para los modelos a construir en el apartado de análisis.

```
# Tabla de contingencia
pclassTable <- table(titanicData$Pclass, titanicData$Survived)
rownames(pclassTable) <- c("Primera clase", "Segunda clase", "Tercera clase")
pclassTable
```

```
##
##                  No  Si
##   Primera clase 137 186
##   Segunda clase 160 117
##   Tercera clase 518 191
```

```
# Mostramos las proporciones (totalizando por fila)
prop.table(pclassTable, 1)
```

```
##
##                        No        Si
```

```
##   Primera clase 0.4241486 0.5758514
##   Segunda clase 0.5776173 0.4223827
##   Tercera clase 0.7306065 0.2693935
```

```
plot(pclassTable, col=brewer.pal(2,"Blues"), main="Supervivencia según clase",
     ylab="Supervivencia", xlab="Clase del pasaje", las=1)
```

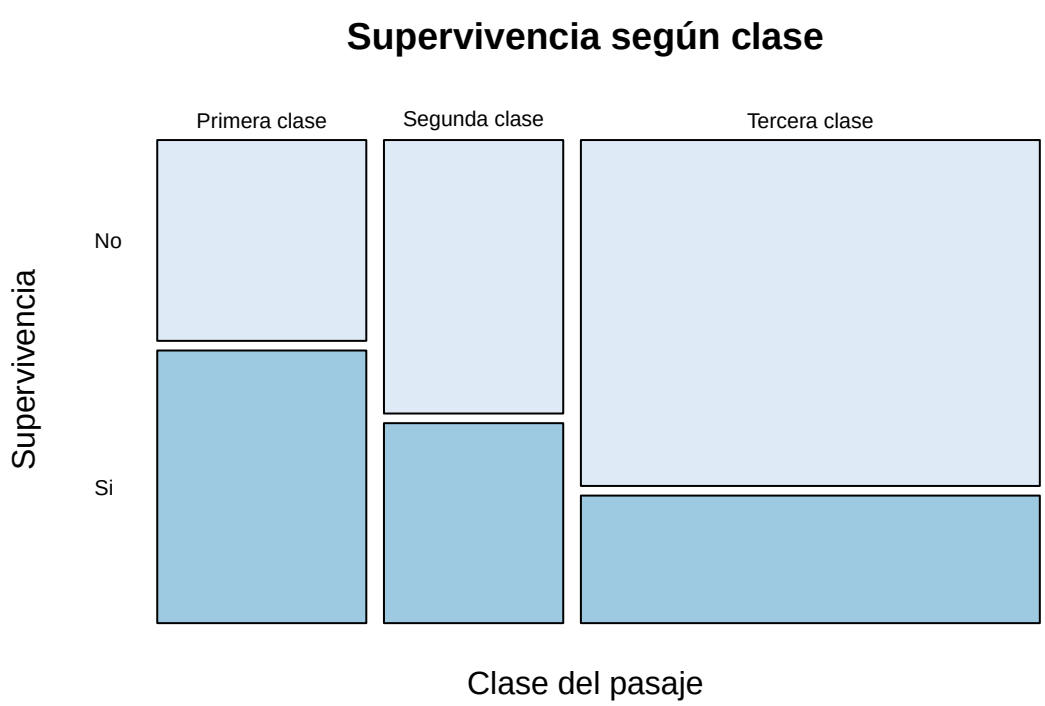

Tanto en las tablas de contingencia como en la gráfica, puede observarse claramente que, a pesar de que el número de pasajeros de tercera clase era mayor, sobrevivieron muchos más pasajeros de primera. De hecho, el porcentaje de fallecidos en tercera es del 73 % aproximadamente, frente al 42 % de primera.

```
# Tabla de contingencia
sexTable <- table(titanicData$Sex, titanicData$Survived)
rownames(sexTable) <- c("Mujer", "Hombre")
sexTable
```

```
##
##           No  Si
##   Mujer   81 385
##   Hombre 734 109
```

```
# Mostramos las proporciones (totalizando por fila)
prop.table(sexTable, 1)
```

```
##
##                 No        Si
##   Mujer  0.1738197 0.8261803
##   Hombre 0.8706999 0.1293001
```

```
plot(sexTable, col=brewer.pal(2,"Blues"), main="Supervivencia según sexo",
     ylab="Supervivencia", xlab="Sexo", las=1)
```

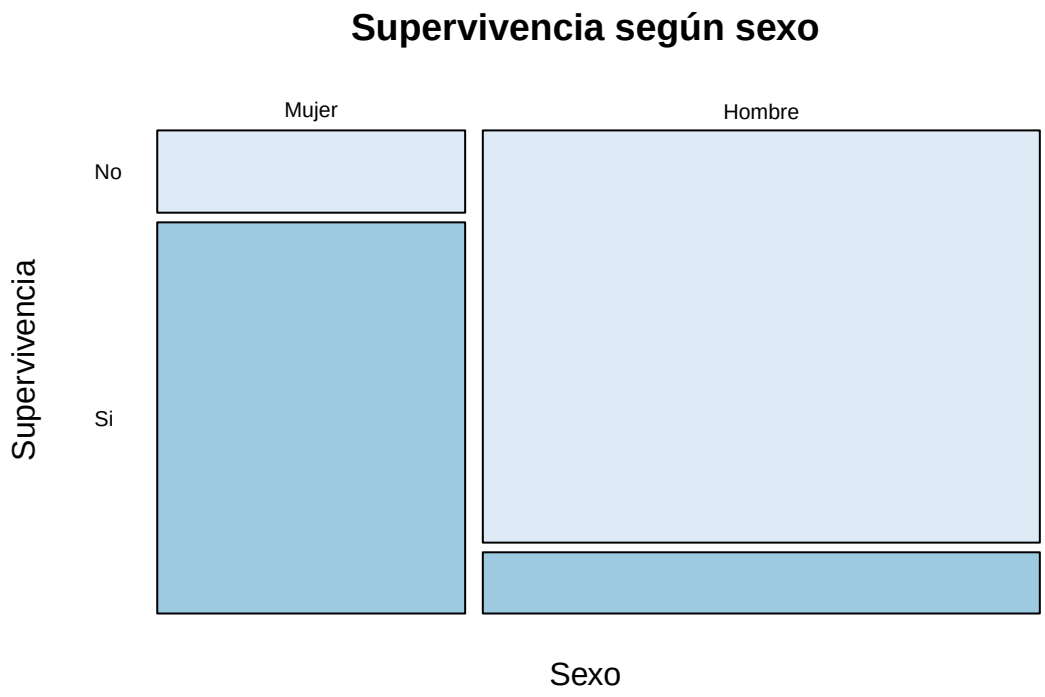

Aunque el número de hombres era superior entre los pasajeros del Titanic, puede verse que la supervivencia fue mucho menor: casi un 83 % de mujeres se salvaron frente a un 13 % de hombres.

```
# Tabla de contingencia
embarkedTable <- table(titanicData$Embarked, titanicData$Survived)
rownames(embarkedTable) <- c("Cherbourg", "Queenstown", "Southampton")
embarkedTable
```

```
##
##                No  Si
##   Cherbourg   137 133
##   Queenstown   69  54
##   Southampton 609 307
```

```
# Mostramos las proporciones (totalizando por fila)
prop.table(embarkedTable, 1)
```

```
##
##                      No        Si
##   Cherbourg   0.5074074 0.4925926
##   Queenstown  0.5609756 0.4390244
##   Southampton 0.6648472 0.3351528
```

```
plot(embarkedTable, col=brewer.pal(2,"Blues"),
     main="Supervivencia según puerto de embarque",
```

```
    ylab="Supervivencia", xlab="Puerto", las=1)
```

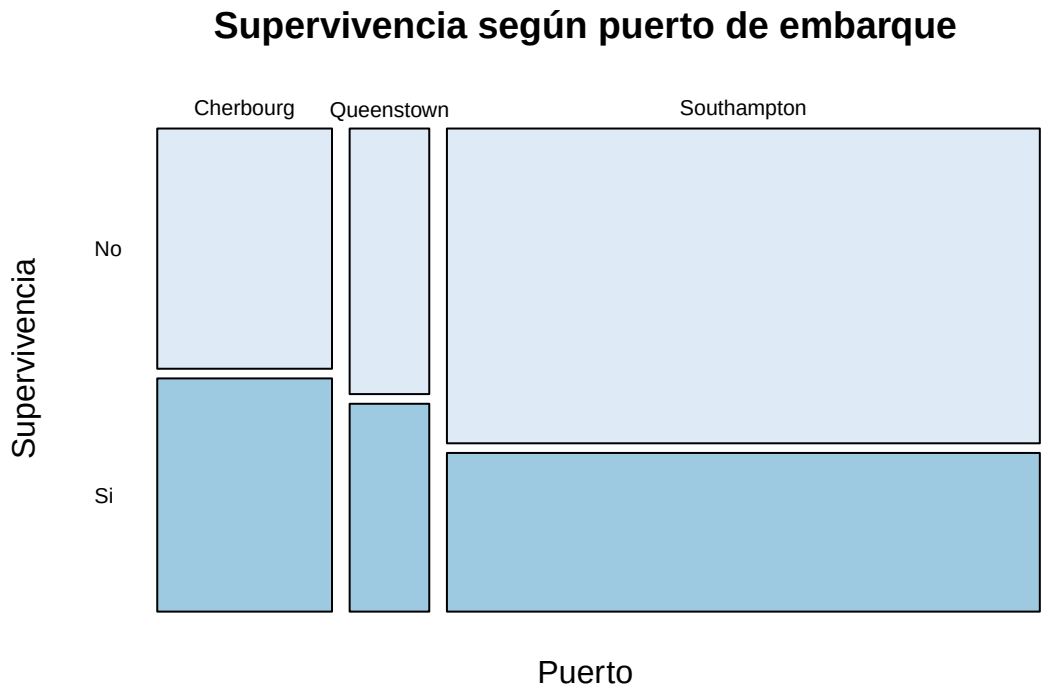

En cuanto al puerto de embarque, se aprecian ciertas diferencias, siendo más relevantes en el caso de Southampton, donde el índice de supervivencia es perceptiblemente menor respecto al siguiente de los puertos (más de 10 puntos porcentuales). Quizá esta discrepancia se deba a otras características comunes que pudieran tener los pasajeros de un puerto u otro, por lo que vamos a investigar más detalladamente la relación de esta variable con otras.

Relación entre variables categóricas

Revisamos la relación entre la clase y el puerto de embarque:

```
# Tabla de contingencia
pclassEmbarkedTable <- table(titanicData$Embarked, titanicData$Pclass)
colnames(pclassEmbarkedTable) <- c("Primera clase", "Segunda clase", "Tercera clase")
rownames(pclassEmbarkedTable) <- c("Cherbourg", "Queenstown", "Southampton")
pclassEmbarkedTable
```

```
##
##               Primera clase Segunda clase Tercera clase
##   Cherbourg             141            28           101
##   Queenstown              3             7           113
##   Southampton           179           242           495
```

```
# Mostramos las proporciones (totalizando por fila)
prop.table(pclassEmbarkedTable, 1)
```

```
##
```

```
##                Primera clase Segunda clase Tercera clase
##   Cherbourg        0.52222222    0.10370370    0.37407407
##   Queenstown       0.02439024    0.05691057    0.91869919
##   Southampton      0.19541485    0.26419214    0.54039301
```

```r
plot(pclassEmbarkedTable, col=brewer.pal(2,"Blues"),
     main="Clase según puerto de embarque",
     ylab="Clase", xlab="Puerto", las=1)
```

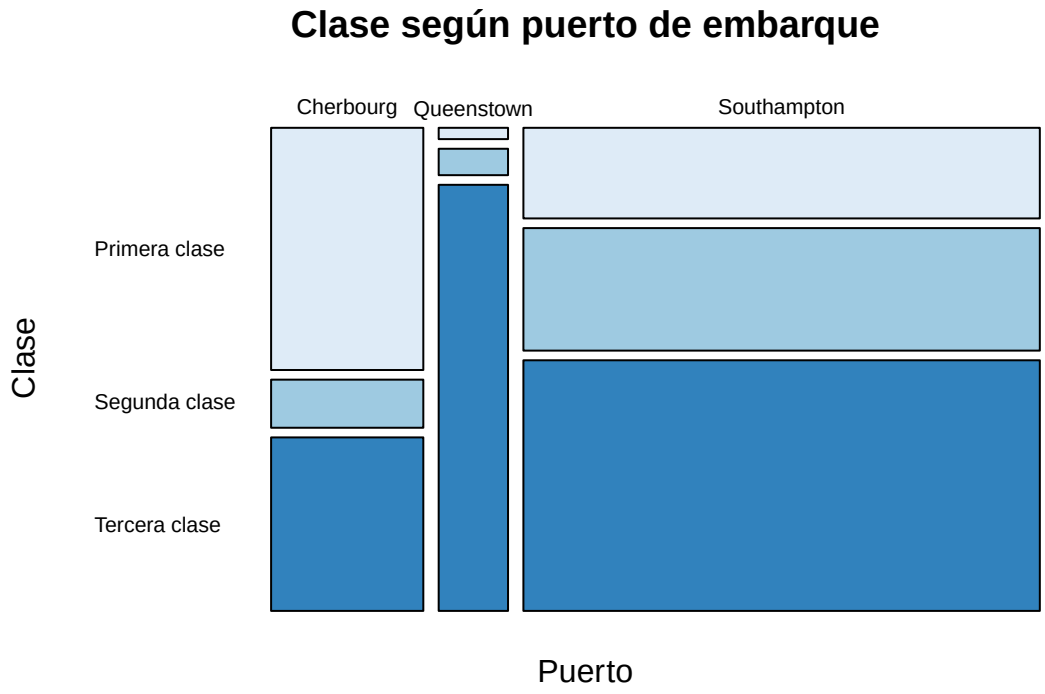

Como puede observarse, la proporción de pasajeros de primera clase que embarcaron en Cherbourg es mucho mayor que los de Southampton (52.2 % vs 19.5 %).

```r
# Tabla de contingencia
pclassEmbarkedFTable <- table(titanicData$Embarked, titanicData$FareD)
colnames(pclassEmbarkedFTable) <- c("Bajo", "Medio", "Alto")
rownames(pclassEmbarkedFTable) <- c("Cherbourg", "Queenstown", "Southampton")
pclassEmbarkedFTable
```

```
##
##                Bajo Medio Alto
##   Cherbourg      59    92  119
##   Queenstown     91    29    3
##   Southampton   295   435  186
```

```r
# Mostramos las proporciones (totalizando por fila)
prop.table(pclassEmbarkedFTable, 1)
```

```
##
```

```
##                      Bajo      Medio       Alto
##   Cherbourg   0.21851852 0.34074074 0.44074074
##   Queenstown  0.73983740 0.23577236 0.02439024
##   Southampton 0.32205240 0.47489083 0.20305677
```

```
plot(pclassEmbarkedFTable, col=brewer.pal(2,"Blues"),
     main="Clase según puerto de embarque",
     ylab="Clase", xlab="Puerto", las=1)
```

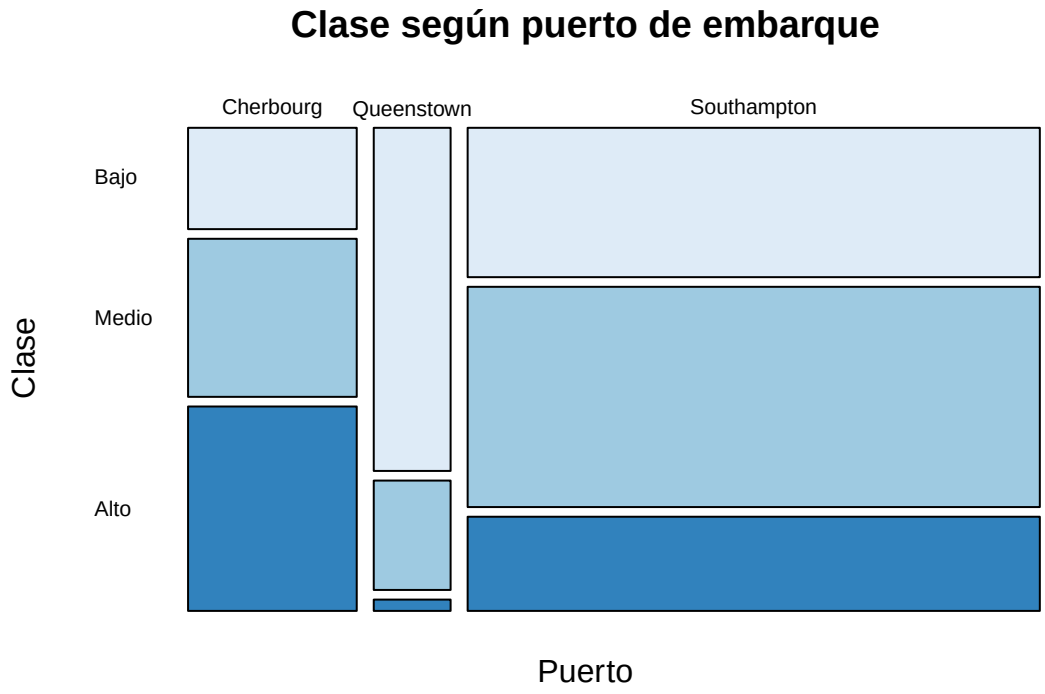

En Cherbourg más de un 40 % de los billetes tenían una tarifa alta, en contraste con Southampton, donde predominaban los de precio medio y bajo, y Queenstown, donde alrededor del 74 % de los billetes eran de coste bajo.

Revisamos ahora la posible relación entre la clase y el precio del billete:

```
# Tabla de contingencia
pclassFareTable <- table(titanicData$Pclass, titanicData$FareD)
colnames(pclassFareTable) <- c("Bajo", "Medio", "Alto")
rownames(pclassFareTable) <- c("Primera clase", "Segunda clase", "Tercera clase")
pclassFareTable
```

```
##
##                 Bajo Medio Alto
##   Primera clase    2    85  236
##   Segunda clase    0   244   33
##   Tercera clase  443   227   39
```

```
# Mostramos las proporciones (totalizando por fila)
prop.table(pclassFareTable, 1)
```

```
##
##                        Bajo      Medio       Alto
##   Primera clase 0.00619195 0.26315789 0.73065015
##   Segunda clase 0.00000000 0.88086643 0.11913357
##   Tercera clase 0.62482370 0.32016925 0.05500705
```

```
plot(pclassFareTable, col=brewer.pal(2,"Blues"),
     main="Precio según Clase",
     ylab="Precio", xlab="Clase", las=1)
```

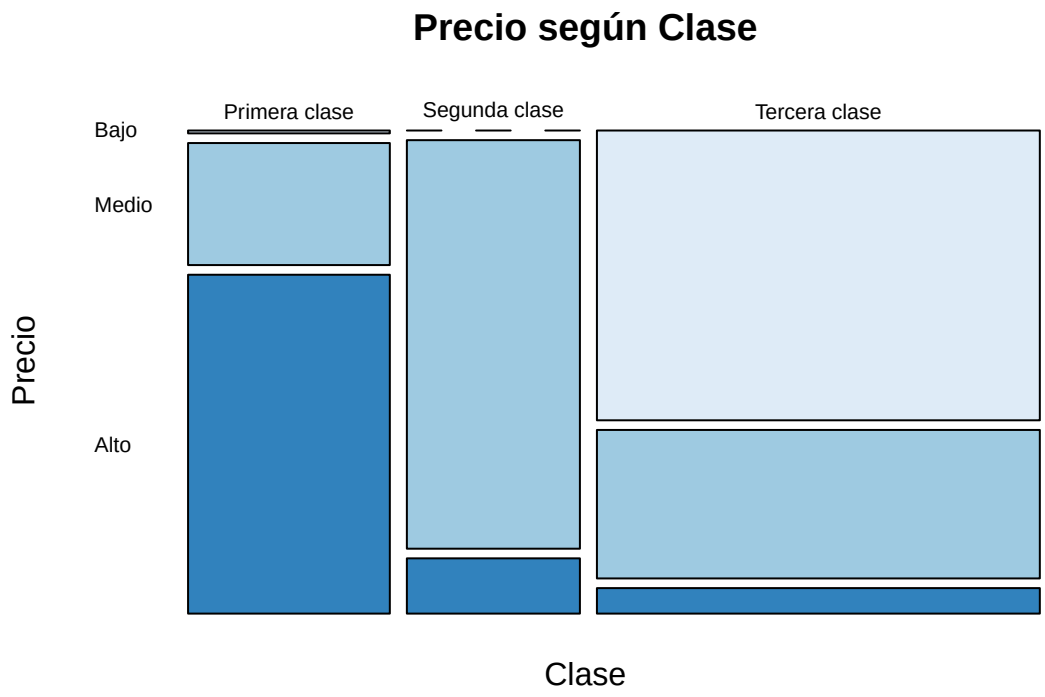

Como era de esperar, la mayor proporción de billetes caros se da en primera clase, los de coste medio están sobre todo ubicados en segunda clase y, por último, los de tercera suelen ser los más baratos.

Por último, se representa la relación entre las variables de clase, precio del billete y supervivencia:

```
# Se visualiza la relación entre Pclass, FareD y Survived
ggplot(data=titanicData[1:length(titanicData$Survived),], aes(x=Pclass, fill=Survived)) +
  geom_bar(position="fill", color="darkblue") + facet_wrap(~FareD) + ylab("frequence") +
  scale_fill_brewer(palette="Blues")
```

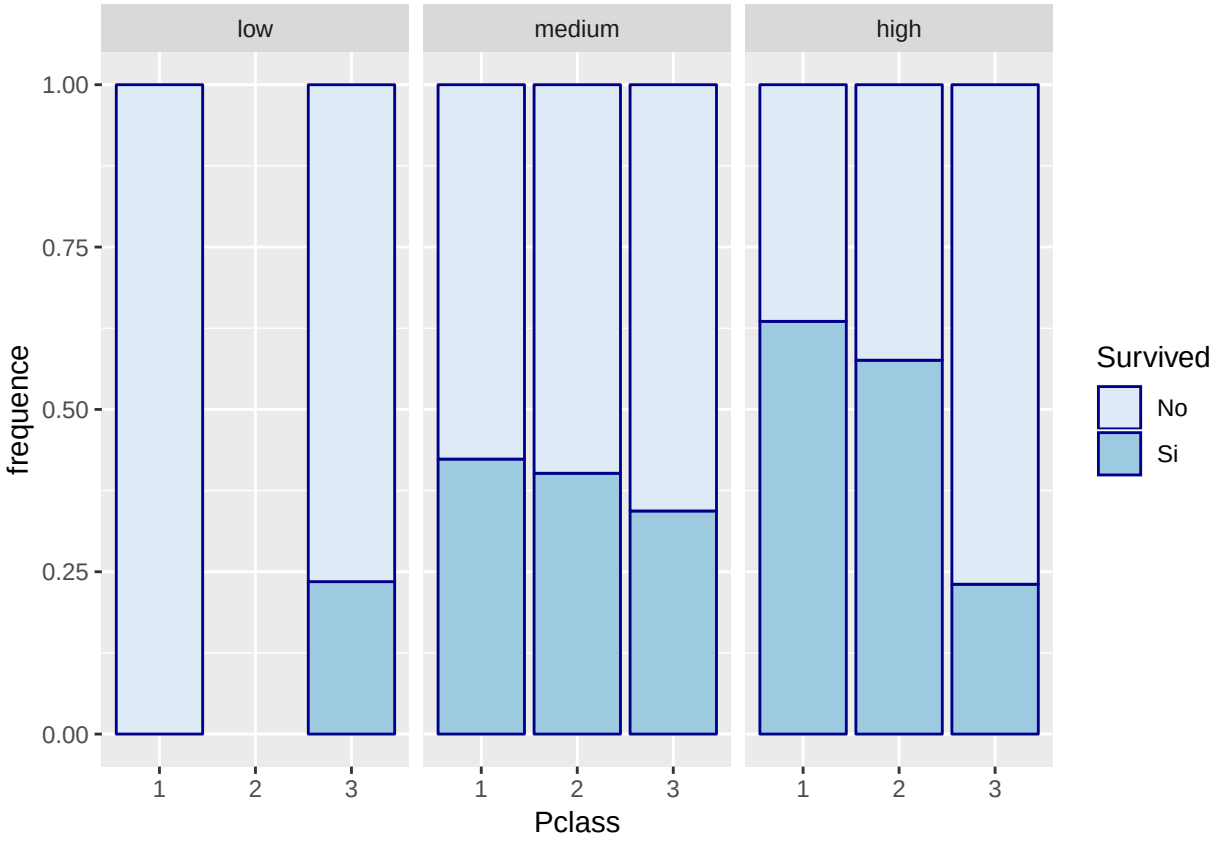

Esta gráfica parece sugerir que, además de la clase, el precio del billete también es relevante, sobre todo en primera y segunda clase, donde el número de supervivientes es mayor si el coste del billete es superior.

Planificación

El análisis que se va a llevar a cabo pretende establecer un modelo de predicción de la variable Survived considerando algunas de las características de los pasajeros del Titanic. Para ello, se ha decidido utilizar tres métodos de predicción distintos:

- Árbol de decisión: se utilizará el algoritmo C5.0. Para aquellas variables numéricas como edad o precio del pasaje, se utilizarán las variables discretizadas que preparamos en apartados anteriores.
- Regresión logística: que nos permite predecir la probabilidad de ocurrencia de una variable dependiente dicotómica (Survived) a partir de la influencia, indicada por unos coeficientes calculados por el algoritmo, de las variables independientes.
- Random Forest: donde se generan varios árboles de decisión simultáneamente incluyendo al azar las variables predictoras.

Comprobación de normalidad y homocedasticidad

En el apartado de análisis de los datos ya tuvimos que aplicar el test de Shapiro-Wilk para seleccionar el método utilizar en el estudio de correlación entre variables. En dicho apartado ya se concluyó que las variables estudiadas no presentaban una distribución normal.

No realizará un estudio de homocedasticidad por no considerarse necesario para el estudio, dado que los métodos que van a emplearse no requieren comparar varianzas entre muestras o conjuntos de población.

Aplicación de pruebas estadísticas

Para la construcción y evaluación de los modelos estadísticos que vamos a aplicar durante este apartado, es preciso separar el conjunto de datos en dos: uno para el entrenamiento de los algoritmos y otro para comprobar la calidad de predicción obtenida.

```
# Semilla pseudoaleatoria
set.seed(0806)

# Se separa el dataset dos partes, training y test, utilizando la función
# createDataPartition del paquete caret
indexTraining <- createDataPartition(y=titanicData$Survived, p=0.75, list=FALSE)

titanicTraining <- titanicData[indexTraining, ]
titanicTest <- titanicData[-indexTraining, ]
```

Comprobamos la distribución de la variable dependiente entre los dos datasets y el original para asegurarnos que no hay sesgo en la división realizada:

```
# Se comprueba la distribución del dataframe original
tmpTable <- prop.table(table(titanicData$Survived))*100
names(dimnames(tmpTable)) <- c("Distribución del dataframe original")
tmpTable
```

```
## Distribución del dataframe original
##       No       Si
## 62.26127 37.73873
```

```
# Se comprueba la distribución del grupo de test
tmpTable <- prop.table(table(titanicTest$Survived))*100
names(dimnames(tmpTable)) <- c("Distribución del grupo de test")
tmpTable
```

```
## Distribución del grupo de test
##       No       Si
## 62.26994 37.73006
```

```
# Se comprueba la distribución del grupo del training
tmpTable <- prop.table(table(titanicTraining$Survived))*100
names(dimnames(tmpTable)) <- c("Distribución del grupo de entrenamiento")
tmpTable
```

```
## Distribución del grupo de entrenamiento
##       No       Si
## 62.25839 37.74161
```

Como puede observarse, las distribuciones son muy similares, por lo que damos por bueno el proceso de división realizado.

Árbol de decisión

Dado que el modelo C50 requiere que todos los datos estén discretizados, se usarán las variables categóricas creadas previamente: AgeD, FareD, SibSpD y ParchD.

```
# Separamos la variable Survived del dataframe de entrenamiento
trainX <- select(titanicTraining, -c("Survived"))
trainY <- select(titanicTraining, c("Survived"))
kable(head(trainX)) %>% kable_styling(latex_options=c("striped", "scale_down"))
```

	PassengerId	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked	AgeD	FareD	SibSpD	ParchD
1	1	3	male	22	1	0	A/5 21171	7.2500	S	adult	low	few	none
2	2	1	female	38	1	0	PC 17599	71.2833	C	adult	high	few	none
3	3	3	female	26	0	0	STON/O2. 3101282	7.9250	S	adult	low	none	none
5	5	3	male	35	0	0	373450	8.0500	S	adult	low	none	none
6	6	3	male	21	0	0	330877	8.4583	Q	adult	low	none	none
7	7	1	male	54	0	0	17463	51.8625	S	adult	high	none	none

```
# Se elimina del conjunto de datos aquellos campos que no se consideran necesarios
trainX <- select(trainX,-c("PassengerId", "Age", "SibSp", "Parch", "Ticket", "Fare"))
```

Una vez eliminados del conjunto de datos los atributos no categóricos y el identificador de pasajero, se procede a entrenar el árbol de decisión.

```
# Se crea el árbol de decisión usando los datos de entrenamiento
model <- C50::C5.0(trainX, trainY$Survived, rules=TRUE)
summary(model)
```

```
##
## Call:
## C5.0.default(x = trainX, y = trainY$Survived, rules = TRUE)
##
##
## C5.0 [Release 2.07 GPL Edition]      Mon May 27 20:17:08 2019
## -------------------------------
##
## Class specified by attribute `outcome'
##
## Read 983 cases (8 attributes) from undefined.data
##
## Rules:
##
## Rule 1: (317/28, lift 1.5)
##  Pclass = 3
##  Sex = male
##  Embarked in {Q, S}
##  ->  class No  [0.909]
##
## Rule 2: (581/63, lift 1.4)
##  Sex = male
##  AgeD in {adult, elder}
##  ->  class No  [0.890]
##
## Rule 3: (380/85, lift 1.2)
##  Pclass = 3
##  Embarked = S
##  ->  class No  [0.775]
##
## Rule 4: (185/6, lift 2.6)
##  Pclass in {1, 2}
##  Sex = female
##  ->  class Si  [0.963]
##
## Rule 5: (299/42, lift 2.3)
##  Sex = female
##  AgeD in {adult, elder}
```

```
##  ->  class Si  [0.857]
##
## Rule 6: (21/3, lift 2.2)
##  Pclass = 2
##  AgeD = kid
##  ->  class Si  [0.826]
##
## Rule 7: (18/3, lift 2.1)
##  Pclass = 3
##  Embarked = C
##  AgeD = kid
##  ->  class Si  [0.800]
##
## Default class: No
##
##
## Evaluation on training data (983 cases):
##
##          Rules
##    ----------------
##      No      Errors
##
##       7  128(13.0%)   <<
##
##
##     (a)   (b)    <-classified as
##    ----  ----
##     563    49    (a): class No
##      79   292    (b): class Si
##
##
##  Attribute usage:
##
##   94.10% Sex
##   93.49% AgeD
##   64.19% Pclass
##   44.35% Embarked
##
##
## Time: 0.0 secs
```

De las reglas obtenidas se observa que los atributos más importantes son el sexo y la edad, seguido de la clase.

Visualizamos el árbol:

```
# Creamos el modelo usando los dataframe de entrenamiento
model <- C50::C5.0(trainX, trainY$Survived)

# Como el gráfico generado es muy grande, se genera una imagen que se añade
# al código
jpeg("c50-plot.jpg", width=1000, height=800)
plot(model)
dev.off()
```

```
## pdf
##   2
```

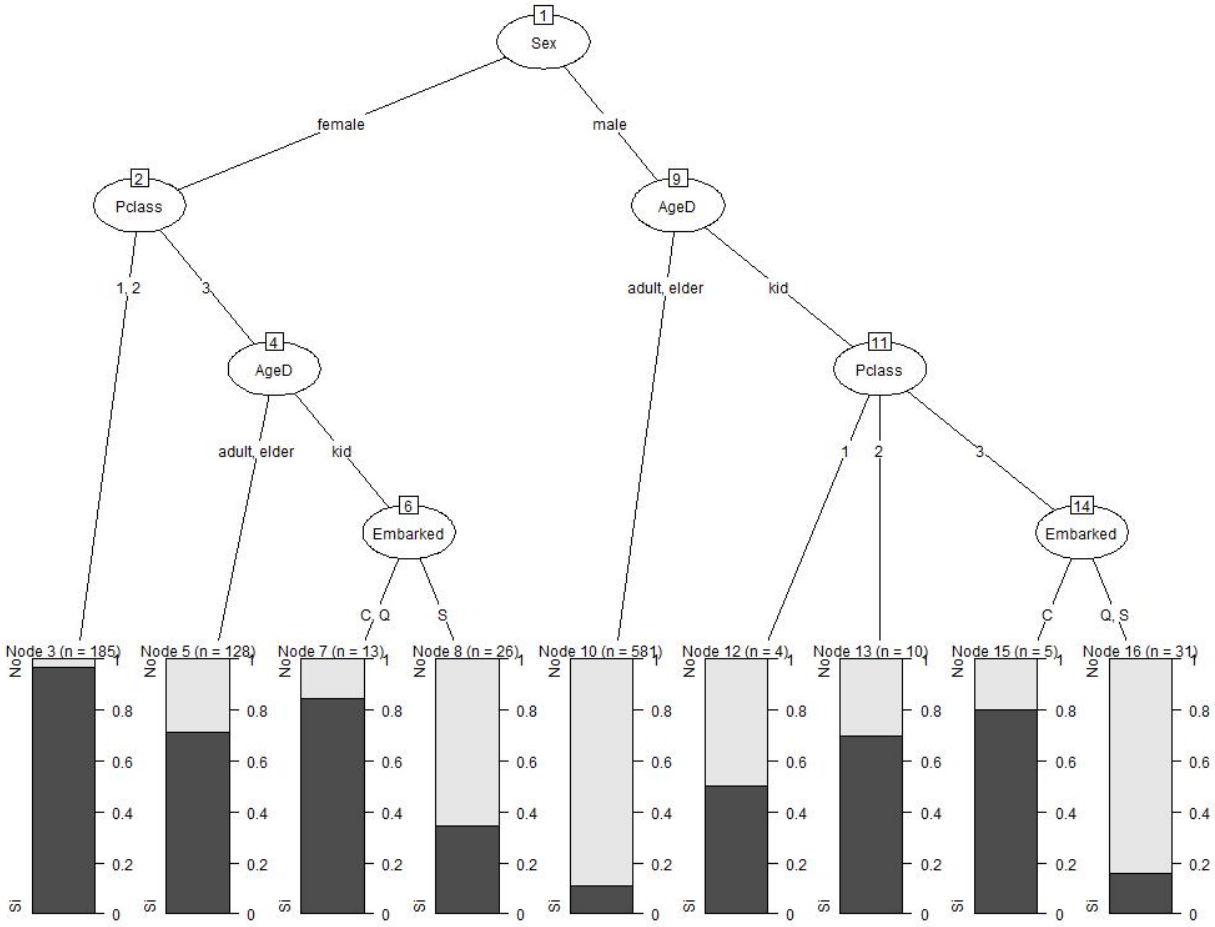

Figura 1: Árbol C50

Se calcula la precisión del modelo, que mide los casos que el modelo ha clasificado correctamente frente al total de registros, con el conjunto de test.

```
# Cálculo de la precisión
predictedModel <- predict(model, titanicTest, type="class")
print(sprintf("La precisión del árbol es: %.4f %%",
              100*sum(predictedModel ==
                        titanicTest$Survived) / length(predictedModel)))
```

```
## [1] "La precisión del árbol es: 84.0491 %"
```

```
# Se muestra la matriz de confusión
matConfC50 <- table(Reales=titanicTest$Survived, Predicciones=predictedModel)
matConfC50
```

```
##       Predicciones
## Reales  No  Si
##     No 181  22
##     Si  30  93
```

En la matriz de confusión se observan 22 falsos positivos y 30 falsos negativos. Es decir, hay 22 casos en lo que el modelo predijo que el pasajero sobrevivió cuando en realidad falleció; y 30 casos en los que los pasajeros fueron clasificados por el modelo como que no habían sobrevivido pero sí lo hicieron.

Como en las reglas generadas por el modelo parece que los atributos con más peso son Sex, AgeD y PClass, se va a reconstruir el modelo sólo con estos atributos para verificar si mejora su rendimiento:

```
# Se eliminan las variables con poco peso en el conjunto de reglas
trainXReduced <- select(trainX,-c("Embarked", "FareD", "SibSpD", "ParchD"))

# Se entrena el nuevo árbol
modelReduced <-C50::C5.0(trainXReduced, trainY$Survived, rules=TRUE)
summary(modelReduced)
```

```
##
## Call:
## C5.0.default(x = trainXReduced, y = trainY$Survived, rules = TRUE)
##
##
## C5.0 [Release 2.07 GPL Edition]      Mon May 27 20:17:09 2019
## -------------------------------
##
## Class specified by attribute `outcome'
##
## Read 983 cases (4 attributes) from undefined.data
##
## Rules:
##
## Rule 1: (631/81, lift 1.4)
##  Sex = male
##  ->  class No  [0.870]
##
## Rule 2: (352/62, lift 2.2)
##  Sex = female
##  ->  class Si  [0.822]
##
## Default class: No
##
```

```
##
## Evaluation on training data (983 cases):
##
##          Rules
##    ----------------
##      No      Errors
##
##       2  143(14.5%)   <<
##
##
##     (a)   (b)    <-classified as
##    ----  ----
##     550    62    (a): class No
##      81   290    (b): class Si
##
##
##  Attribute usage:
##
##  100.00% Sex
##
##
## Time: 0.0 secs
```

Se representa gráficamente el modelo obtenido:

```
# Creamos el modelo usando los dataframe de entrenamiento
modelReduced <-C50::C5.0(trainXReduced, trainY$Survived)

# Como el gráfico generado es muy grande, se genera una imagen que se añade
# al código
jpeg("c50-plot-reduced.jpg", width=1000, height=800)
plot(modelReduced)
dev.off()
```

```
## pdf
##   2
```

Como en el caso anterior, se mide su precisión y se muestra su matriz de confusión:

```
# Se predicen los resultados del grupo de test
predModelReduced <- predict(modelReduced, titanicTest, type="class")
print(sprintf("La precisión del árbol es: %.4f %%",
              100*sum(predModelReduced ==
                        titanicTest$Survived) / length(predModelReduced)))
```

```
## [1] "La precisión del árbol es: 85.5828 %"
```

```
# Se muestra la matriz de confusión
matConfC50 <- table(Reales=titanicTest$Survived, Predicciones=predModelReduced)
matConfC50
```

```
##       Predicciones
## Reales  No  Si
##     No 184  19
##     Si  28  95
```

Como se puede comprobar, el segundo modelo generado tiene un porcentaje ligeramente mayor de acierto, a pesar de utilizar sólo una variable en las reglas de decisión.

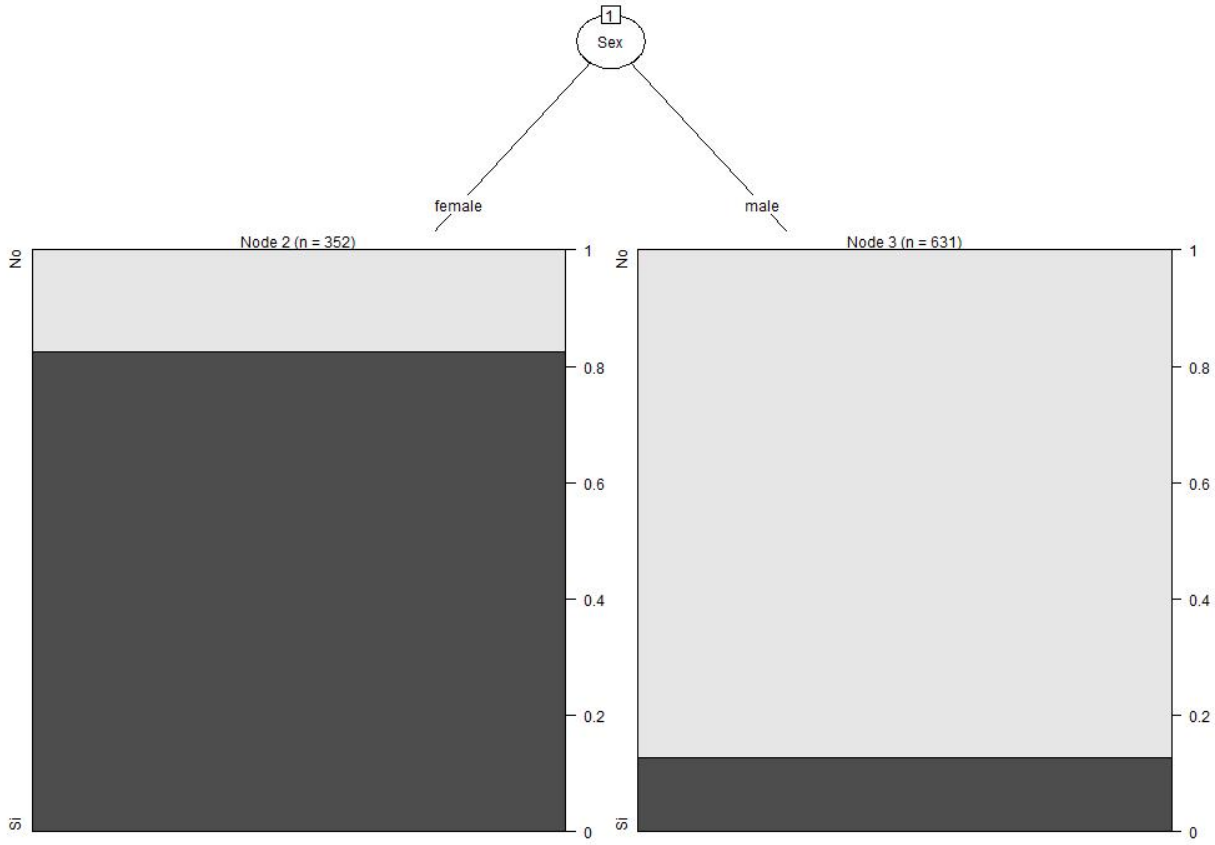

Figura 2: Árbol C50 reducido

Modelo de regresión logística

Con el objetivo de intentar mejorar el desempeño de los modelos anteriores, vamos a cambiar de técnica y a utilizar un modelo de regresión logística. En él, se evaluará la probabilidad de que un pasajero sobreviva al hundimiento (variable dependiente dicotómica) mediante el uso de ciertas variables explicativas.

Nuestra primera versión del modelo utiliza como variables predictoras todas las variables originales del dataset (a excepción de las descartadas al comienzo de la práctica).

```
# Se procede a evaluar el modelo de regresión logística: se indica family=binomial para
# que se aplique un modelo logit
modelGlm <- glm(Survived ~ Pclass+Sex+Age+SibSp+Parch+Fare+Embarked, family=binomial,
                data=titanicTraining)
summary(modelGlm)
```

```
##
## Call:
## glm(formula = Survived ~ Pclass + Sex + Age + SibSp + Parch +
##     Fare + Embarked, family = binomial, data = titanicTraining)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.6934  -0.4870  -0.3502   0.4945   2.7064
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  4.233199   0.494223   8.565  < 2e-16 ***
## Pclass2     -1.211916   0.325683  -3.721 0.000198 ***
## Pclass3     -2.188246   0.333422  -6.563 5.27e-11 ***
## Sexmale     -3.732925   0.218236 -17.105  < 2e-16 ***
## Age         -0.029844   0.008077  -3.695 0.000220 ***
## SibSp       -0.251142   0.099595  -2.522 0.011681 *
## Parch       -0.043807   0.113781  -0.385 0.700227
## Fare        -0.000397   0.002754  -0.144 0.885356
## EmbarkedQ    0.145007   0.418228   0.347 0.728804
## EmbarkedS   -0.174228   0.251740  -0.692 0.488876
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1303.04  on 982  degrees of freedom
## Residual deviance:  727.97  on 973  degrees of freedom
## AIC: 747.97
##
## Number of Fisher Scoring iterations: 5
```

Revisando los coeficientes estimados para cada variable, puede deducirse que:

- La probabilidad de sobrevivir de los pasajeros de 2ª y 3ª clase era inferior a la de los pasajeros de 1ª. En concreto, la clase con menor probabilidad de supervivencia era 3ª.
- Los hombres tenían menor probabilidad de sobrevivir que las mujeres.
- La edad muestra una relación negativa con la probabilidad de supervivencia: es decir, a mayor edad, menor probabilidad.
- El número de hermanos/cónyuges, así como el número de padres/hermanos, muestran también una relación negativa: cuanto mayor es el número de familiares, menor es la probabilidad de sobrevivir.
- En cuanto al precio del pasaje, en contra de lo que pudiera parecer inicialmente teniendo en cuenta

que los pasajeros de 1ª tenían más posibilidades de sobrevivir y son los que suelen tener que pagar un billete más caro, parece haber una ligera relación negativa entre esta variable y la dependiente. En cualquier caso, este coeficiente presenta un valor muy bajo y además, como veremos a continuación, no tiene influencia significativa.
- Respecto al puerto de embarque, y tomando como referencia Cherbourg, los pasajeros de Queenstown parece que tenían mayor probabilidad de sobrevivir, mientras que los de Southampton tenían menos. No obstante, estas variables tampoco presentan una significación estadística suficiente.

Como ya se ha comentado, no todas las variables utilizadas son significativas. Comprobamos cuáles lo son revisando sus p-valores individuales (deben ser inferiores a 0.05):

```
# Revisamos qué regresores tienen una influencia significativa:

# Número de coeficientes del modelo
numCoefLogit <- length(coefficients(modelGlm))

# Se visualizan los p-valores individuales de los registros que se corresponden con las
# variables explicativas
summary(modelGlm)$coefficients[2:numCoefLogit, "Pr(>|z|)"]
```

```
##      Pclass2      Pclass3      Sexmale          Age        SibSp
## 1.983135e-04 5.274057e-11 1.361862e-65 2.200978e-04 1.168118e-02
##        Parch         Fare    EmbarkedQ    EmbarkedS
## 7.002272e-01 8.853563e-01 7.288038e-01 4.888758e-01
```

```
# Y se comprueba cuáles tienen el p-valor de su contraste menor que 0.05
summary(modelGlm)$coefficients[2:numCoefLogit, "Pr(>|z|)"] < 0.05
```

```
##   Pclass2   Pclass3   Sexmale       Age     SibSp     Parch      Fare
##      TRUE      TRUE      TRUE      TRUE      TRUE     FALSE     FALSE
## EmbarkedQ EmbarkedS
##     FALSE     FALSE
```

Escogemos sólo estas variables como explicativas para construir un nuevo modelo:

```
# Se procede a evaluar el modelo de regresión logística
modelGlm2 <- glm(Survived ~ Pclass+Sex+Age+SibSp, family=binomial, data=titanicTraining)
summary(modelGlm2)
```

```
##
## Call:
## glm(formula = Survived ~ Pclass + Sex + Age + SibSp, family = binomial,
##     data = titanicTraining)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.7491  -0.4898  -0.3503   0.4960   2.8121
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  4.095840   0.419501   9.764  < 2e-16 ***
## Pclass2     -1.240226   0.281924  -4.399 1.09e-05 ***
## Pclass3     -2.157011   0.265077  -8.137 4.04e-16 ***
## Sexmale     -3.737890   0.211648 -17.661  < 2e-16 ***
## Age         -0.029694   0.008033  -3.697 0.000219 ***
## SibSp       -0.280908   0.093817  -2.994 0.002752 **
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1303.04  on 982  degrees of freedom
## Residual deviance:  729.38  on 977  degrees of freedom
## AIC: 741.38
##
## Number of Fisher Scoring iterations: 5
```

```
# Revisamos qué regresores tiene una influencia significativa:

# Número de coeficientes del modelo
numCoefLogit <- length(coefficients(modelGlm2))

# Se visualizan los p-valores individuales de los registros que se corresponden con las
# variables explicativas
summary(modelGlm2)$coefficients[2:numCoefLogit, "Pr(>|z|)"]
```

```
##      Pclass2      Pclass3      Sexmale          Age        SibSp
## 1.086757e-05 4.041576e-16 8.389561e-70 2.185228e-04 2.751624e-03
```

```
# Y se comprueba cuáles tienen el p-valor de su contraste menor que 0.05
summary(modelGlm2)$coefficients[2:numCoefLogit, "Pr(>|z|)"] < 0.05
```

```
## Pclass2 Pclass3 Sexmale     Age   SibSp
##    TRUE    TRUE    TRUE    TRUE    TRUE
```

Como puede observarse, todas las variables aparecen ahora como significativas. El sentido y significado de los coeficientes obtenidos son similares a los del primer modelo.

Para la comparación de este tipo de modelos suele utilizarse la medida AIC, que permite evaluar la bondad del modelo teniendo en consideración también su complejidad. El modelo escogido es aquel que tiene un AIC menor, que en este caso es el segundo que hemos generado, con un AIC de 741.38 frente al del primero, de 747.97.

Realizamos la matriz de confusión del modelo seleccionado para medir su rendimiento utilizando el conjunto de datos de prueba.

```
# Se predice la variable Survived del conjunto de test mediante el modelo creado
predictionsGlm <- predict(modelGlm2, titanicTest, type="response")

# Para poder confrontar las predicciones con los resultados reales, debemos recodificar
# las predicciones teniendo en cuenta un umbral establecido: si es mayor o igual a 0.75,
# le asignamos un "Si" (sobrevivió); en caso contrario, un "No"
predictions <- ifelse(predictionsGlm >= 0.75, "Si", "No")

# Mostramos la matriz
matConfGlm <- table(Reales=titanicTest$Survived, Predicciones=predictions)
matConfGlm
```

```
##       Predicciones
## Reales  No  Si
##     No 199   4
##     Si  39  84
```

En la matriz de confusión se observan 4 falsos positivos y 39 falsos negativos. Es decir, hay 4 casos en lo que el modelo predijo que había una alta probabilidad de que el pasajero sobreviviese cuando en realidad falleció; y 39 casos en los que los pasajeros tenían una baja probabilidad de sobrevivir pero lo hicieron.

Random forest

En este apartado se hace uso del algoritmo predictivo **random forest**, que realiza distintas combinaciones de árboles de decisión utilizando distintas observaciones y variables en cada uno de ellos. Para la predicción de la variable contabiliza los resultados de la misma obtenidos en todos los árboles y da por bueno aquel que se repite en más ocasiones.

Realizaremos dos modelos: uno que considera las variables Age, SibSp, Parch y Fare originales del dataset y otro que considera sus versiones discretizadas.

```
# Preparamos el conjunto de entrenamiento: mantenemos las versiones discretizadas de las
# variables Age, SibSp, Parch y Fare
trainRF <- select(titanicTraining,-c("PassengerId", "Age", "SibSp", "Parch",
                                     "Ticket", "Fare"))

# Construimos el primer modelo
modelRF <- randomForest(Survived~., data=trainRF)
modelRF
```

```
##
## Call:
##  randomForest(formula = Survived ~ ., data = trainRF)
##                Type of random forest: classification
##                      Number of trees: 500
## No. of variables tried at each split: 2
##
##         OOB estimate of  error rate: 14.14%
## Confusion matrix:
##     No  Si class.error
## No 556  56  0.09150327
## Si  83 288  0.22371968
```

```
# Realizamos las pruebas sin considerar las variables discretizadas de Age, SibSp, Parch
# y Fare
trainRF2 <- select(titanicTraining,-c("PassengerId", "AgeD", "SibSpD", "ParchD",
                                      "Ticket", "FareD"))
# Construimos el segundo modelo
modelRF2 <- randomForest(Survived~., data=trainRF2)
modelRF2
```

```
##
## Call:
##  randomForest(formula = Survived ~ ., data = trainRF2)
##                Type of random forest: classification
##                      Number of trees: 500
## No. of variables tried at each split: 2
##
##         OOB estimate of  error rate: 13.94%
## Confusion matrix:
##     No  Si class.error
## No 556  56  0.09150327
## Si  81 290  0.21832884
```

El error estimado (OOB error) de ambos modelos es muy parejo, por lo que se puede concluir que tienen un desempeño similar. Seleccionamos el segundo de ellos y creamos una gráfica a continuación donde aparece:

- En color verde, el error cometido para el caso en que Survived=Si.
- En color rojo, el error cometido para el caso en que Survived=No.

- En color negro, el OOB error.

```
# Se muestra la gráfica del modelo construido
plot(modelRF2, main="Resumen de errores del modelo")
```

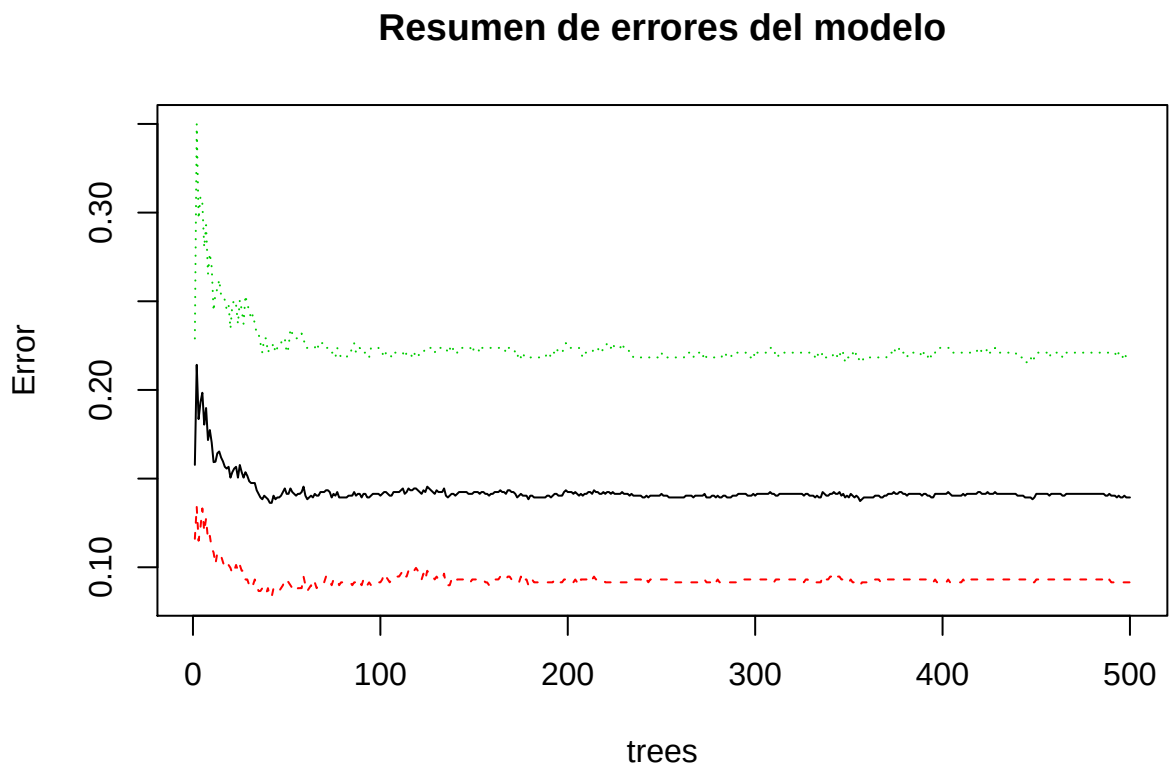

Vamos a revisar qué variables han tenido más relevancia en la elaboración del modelo:

```
# Gráfica con el nivel de importancia de las variables
varImpPlot(modelRF2, main="Importancia de las variables")
```

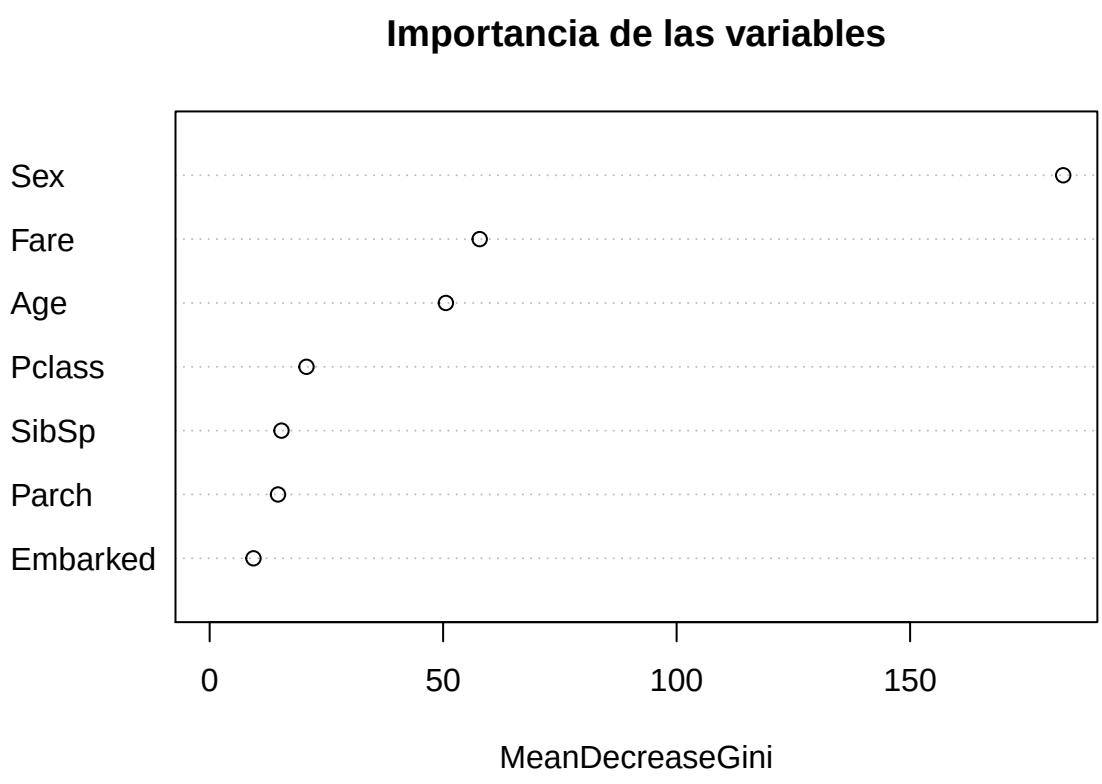


```
# Tabla con el detalle
importance(modelRF2)
```

```
##          MeanDecreaseGini
## Pclass          20.736381
## Sex            182.790362
## Age             50.584900
## SibSp           15.380051
## Parch           14.636209
## Fare            57.825067
## Embarked         9.384893
```

Cuanto mayor es el valor, más importante es la variable: puede observarse que el sexo del pasajero es el factor más determinante, seguido por el precio del pasaje y la edad.

```
# Se predicen los valores del conjunto de prueba
predictionsRF <- predict(modelRF2, newdata=titanicTest)

# Se genera y muestra la matriz de confusión
matConfRF <- table(Reales=titanicTest$Survived, Predicciones=predictionsRF)
matConfRF
```

```
##       Predicciones
## Reales  No  Si
##     No 185  18
##     Si  27  96
```

En la matriz de confusión se observan 18 falsos positivos (pasajeros fallecidos que según el modelo tenían

una alta probabilidad de sobrevivir) y 27 falsos negativos (pasajeros que sobrevivieron aunque el modelo les asigna una probabilidad de supervivencia muy baja).

Representación de los resultados

Para poder evaluar qué modelo es el más apropiado de los tres seleccionados en sus respectivos apartados, vamos a representar las curvas ROC de las predicciones realizadas por cada uno de ellos sobre el conjunto de pruebas. Se seleccionará aquel modelo con mayor AUC (area under the curve) como el más adecuado.

```
# Se realizan las prediciones de los modelos del árbol de decisión y random forest con la
# opción de obtener las probabilidades (type="prob")
predictionsProbTree <- predict(modelReduced, titanicTest, type="prob")

# Se predicen los valores del conjunto de prueba
predictionsProbRF <- predict(modelRF2, titanicTest, type="prob")
```

Se construyen las curvas superpuestas en la misma gráfica:

```
# Construimos la curva ROC para el modelo con árbol de decisión
rocTree <- roc(titanicTest$Survived, predictionsProbTree[, 2], col="blue", plot=TRUE,
               legacy.axes=TRUE, lwd=2, print.auc=TRUE, print.auc.y=50, percent=TRUE,
               xlab="1 - Especificidad (%)", ylab="Sensibilidad (%)")

# Construimos la curva ROC para el modelo de regresión logística
rocLogit <- roc(titanicTest$Survived, predictionsGlm, col="green",
                plot=TRUE, legacy.axes=TRUE, lwd=2, print.auc=TRUE, add=TRUE,
                print.auc.y=60, percent=TRUE)

# Construimos la curva ROC para el modelo random forest y la pintamos junto con las
# anteriores
rocForest <- plot.roc(titanicTest$Survived, predictionsProbRF[, 2], col="orange",
                      lwd=2, print.auc=TRUE, add=TRUE, print.auc.y=70, percent=TRUE,
                      main="Comparación de curvas ROC")

# Leyenda del gráfico
legend("bottomright", legend=c("Modelo Árbol", "Modelo Logit", "Modelo Random Forest"),
       col=c("blue", "green", "orange"), lwd=2)
```

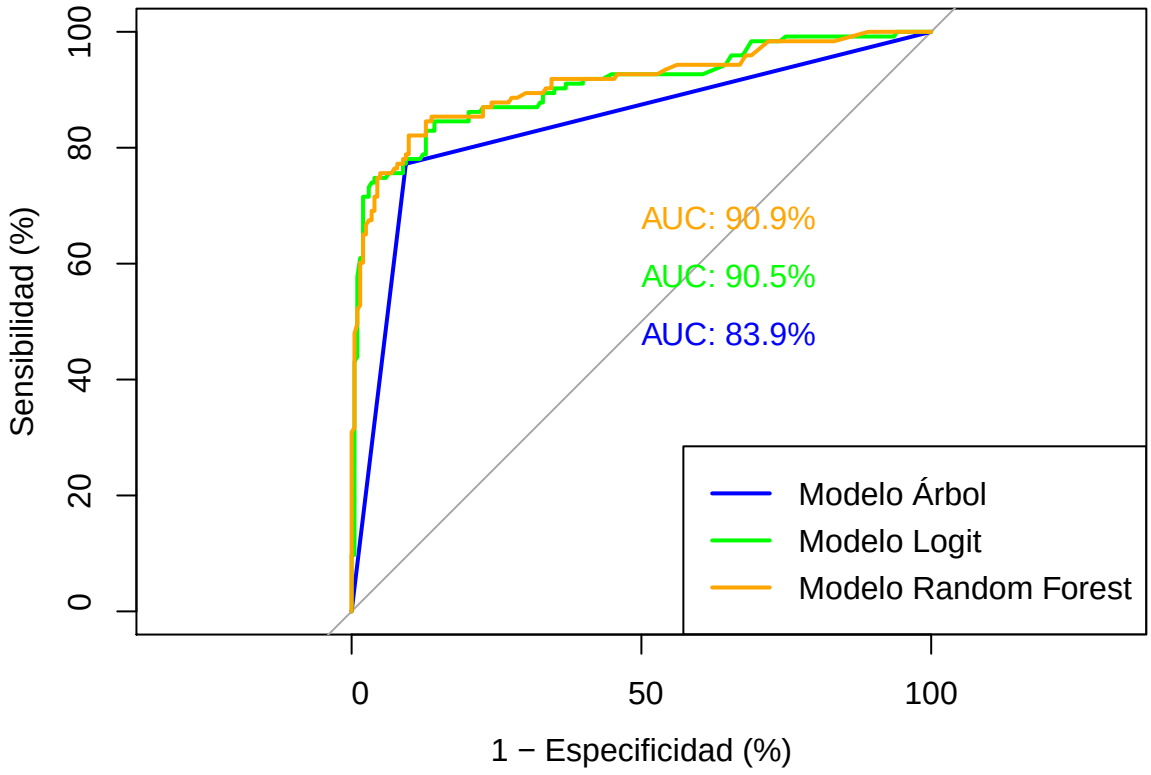

Según los valores de AUC obtenidos, el mejor de los modelos es el construido con la técnica de random forest, seguido muy de cerca por el de regresión logística.

Conclusiones

Dado que aproximadamente el 63 % de las personas que viajaban en el Titanic **no** sobrevivieron (valor mayoritario o moda, correspondiente a la variable Survived), cualquier modelo que se construya debe tener una precisión mayor que este porcentaje.

Tras la construcción y evaluación de varios modelos predictivos, hemos concluido que el mejor de ellos se basa en el algoritmo de random forest. Para realizar esta comparativa entre modelos se ha utilizado la métrica AUC, que permite comparar la calidad de los modelos, calculando el área debajo de la curva ROC de cada uno de ellos.

En los tres modelos pre-seleccionados, se ha concluido que la variable más significativa es el sexo. De hecho, el modelo más preciso alcanzado con árboles de decisión, terminó utilizando sólo esta variable. Esta sobresimplificación del problema, "las mujeres sobreviven, los hombres no", conlleva a que el modelo tenga que ser descartado, aunque su precisión sea mayor que otros árboles de decisión obtenidos, y a que se decida utilizar otro tipo de técnicas.

Revisando las siguientes variables con mayor peso en la predicción, observamos diferencias entre el modelo de regresión lineal y el modelo de random forest:

```
##
## Call:
## glm(formula = Survived ~ Pclass + Sex + Age + SibSp, family = binomial,
##     data = titanicTraining)
##
```

```
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.7491  -0.4898  -0.3503   0.4960   2.8121
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  4.095840   0.419501   9.764  < 2e-16 ***
## Pclass2     -1.240226   0.281924  -4.399 1.09e-05 ***
## Pclass3     -2.157011   0.265077  -8.137 4.04e-16 ***
## Sexmale     -3.737890   0.211648 -17.661  < 2e-16 ***
## Age         -0.029694   0.008033  -3.697 0.000219 ***
## SibSp       -0.280908   0.093817  -2.994 0.002752 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1303.04  on 982  degrees of freedom
## Residual deviance:  729.38  on 977  degrees of freedom
## AIC: 741.38
##
## Number of Fisher Scoring iterations: 5
```

Mientras que para el modelo de regresión logística la siguiente variable en importancia es Pclass (clase del pasaje), para el de random forest las siguientes variables en importancia son Fare (coste del billete) y Age (edad del pasajero). De hecho, la variable Fare fue eliminada en el segundo modelo de regresión construido al

concluir que no era una variable significativa.

A priori, parece natural que hubiera una relación directa entre las variables Fare y Pclass, ya que el precio del billete debería venir determinado por el tipo de clase. Sin embargo, en el apartado de análisis descriptivo visual ya se comprobó con varios gráficos que esta circunstancia no siempre es cierta, y por ello se mantuvieron ambas variables en el estudio.

Siguiendo con la revisión de la importancia de variables para random forest, se observa que el precio del billete tiene un peso superior al de la clase del pasaje. Esto parece sugerir que no es tanto la clase, sino los camarotes más caros lo que aumenta las posibilidades de supervivencia. Quizá la ubicación de estos camarotes fuese más cercana a las cubiertas donde se encontrasen los botes salvavidas, y de ahí su influencia en el modelo.

Considerando además el peso y los resultados obtenidos para la edad y el sexo, se puede concluir que en el hundimiento del Titanic sí se siguió la norma no escrita de "las mujeres y los niños primero".

Código fuente

El código generado para la realización de esta práctica se encuentra disponible en https://github.com/azucenagm/Titanic.

Bibliografía

Grolemund, Garrett; Wickham, Hadley (2016). *R for Data Science* (1ª ed.). Sebastopol: O'Reilly Media, Inc.

Teetor, Paul; Long, JD (2019). *R Cookbook* (2ª ed.). Sebastopol: O'Reilly Media, Inc.

Santana, Enmanuel (2014, noviembre). "Machine Learning con R: ejemplo de Random Forest". *Apuntes R* [artículo en línea]. [Fecha de consulta: 22 de mayo de 2019]. http://apuntes-r.blogspot.com/2014/11/ejemplo-de-random-forest.html

Singh, Anish (2018, mayo). "Random Forests in R". *Data Science Plus* [artículo en línea]. [Fecha de consulta: 23 de mayo de 2019]. https://datascienceplus.com/random-forests-in-r/

"How do I interpret the AIC" (2018, abril). *R-bloggers* [artículo en línea]. [Fecha de consulta: 20 de mayo de 2019]. https://www.r-bloggers.com/how-do-i-interpret-the-aic

"Precios y descripción de los camarotes". *El hundimiento* [artículo en línea]. [Fecha de consulta: 25 de mayo de 2019]. https://elhundimiento.weebly.com/precios-clases-y-distribucioacuten-de-los-camarotes.html

"Qué incluía el billete más caro del Titanic" (2016, abril). *Traveler* [artículo en línea]. [Fecha de consulta: 25 de mayo de 2019]. https://www.traveler.es/experiencias/articulos/billete-mas-caro-titanic/8724

"RMS Titanic" (2019, mayo) *Wikipedia* [artículo en línea]. [Fecha de consulta: 25 de mayo de 2019]. https://es.wikipedia.org/wiki/RMS_Titanic%22

"ROC and AUC in R" (2018, diciembre). *Statquest* [artículo en línea]. [Fecha de consulta: 24 de mayo de 2019]. https://statquest.org/2018/12/17/roc-and-auc-in-r/